

MCDI504

MACHINE LEARNING I

AVANCE DEL PROYECTO — FASE 1: DEFINICIÓN Y ORIENTACIÓN DE LA SITUACIÓN

Nombre integrantes:

Luis Díaz Giral
Gonzalo Bouldres
Eduardo Contreras

Curso: MCDI504
Machine Learning I
Grupo 6

Docente: Dr. David Ruete Zúñiga

Fecha: 08-08-2026

APARTADOS

- I. Portada e índice
- II. Introducción y contextualización
- III. Definición de la problemática y objetivos del proyecto
- IV. Clasificación del tipo de aprendizaje
- V. Relación entre Machine Learning y metodología KDD
- VI. Notebook F1_Definición.ipynb
- VII. Comparación de enfoques
- VIII. Documentación del proceso
- IX. Conclusiones
- X. Uso de fuentes, citación y referencias
- XI. Anexos

II. Introducción y contextualización

La Fase 1 del proyecto ABP se orienta a convertir una situación de análisis en un problema de ciencia de datos formalmente definido, identificando la estructura de los datos, la variable objetivo y el enfoque de aprendizaje que deberá guiar las fases posteriores. Para este avance se utiliza IrisFlow, un escenario ficticio de recepción y clasificación de flores Iris en el que se plantea que la asignación manual de especie puede presentar inconsistencias cuando las diferencias morfológicas son pequeñas o la decisión depende exclusivamente de observación experta.

El análisis se sustenta en el dataset Iris cargado mediante scikit-learn, compuesto por cuatro variables morfológicas continuas longitud y ancho de sépalo, y longitud y ancho de pétalo y una etiqueta categórica nominal, Species, con tres clases conocidas: setosa, versicolor y virginica. La disponibilidad de una etiqueta para cada observación permite representar el problema como una tarea de clasificación supervisada multiclase (Ruede, 2026b; scikit-learn developers, s. f.; Pedregosa et al., 2011).

El objetivo analítico de esta fase es establecer si la estructura, calidad y características exploratorias del dataset permiten formular de manera consistente un problema de Machine Learning supervisado para clasificar Species a partir de las medidas morfológicas disponibles. En consecuencia, la relación central del proyecto queda definida por cuatro predictores numéricos como entradas, una etiqueta nominal conocida como salida y un propósito analítico de asignación de clase. La Fase 1 no entrena modelos: construye y documenta la base conceptual, técnica y reproducible que orientará el modelamiento posterior.

III. Definición de la problemática y objetivos del proyecto

3.1 Formulación del problema

El problema analítico consiste en determinar si las variables morfológicas disponibles y la calidad inicial del dataset permiten estructurar una tarea de clasificación multiclase coherente, reproducible y compatible con el proceso KDD. Esto requiere verificar la integridad del conjunto de datos, caracterizar sus variables, documentar condiciones que puedan afectar etapas posteriores y justificar el enfoque de aprendizaje antes de seleccionar o entrenar algoritmos.

3.2 Pregunta analítica

¿Cómo permiten las variables morfológicas Sepal.Length, Sepal.Width, Petal.Length y Petal.Width estructurar un problema de aprendizaje supervisado para la clasificación multiclase de Species dentro del proceso KDD?

3.3 Objetivo general

Definir y justificar el enfoque metodológico inicial para la clasificación de especies Iris mediante la caracterización estructural, descriptiva y exploratoria del dataset y su articulación con las etapas del proceso KDD.

3.4 Objetivos específicos

1. Verificar dimensiones, tipos de datos, completitud, registros con combinaciones coincidentes y distribución de Species.
2. Caracterizar las variables predictoras mediante estadística descriptiva y análisis de valores atípicos.
3. Examinar relaciones lineales entre variables numéricas mediante correlación de Pearson y valores p.
4. Aplicar una codificación temporal de Species únicamente como apoyo exploratorio, preservando su naturaleza nominal.

5. Normalizar las variables predictoras mediante Min-Max y verificar el rango resultante.
6. Justificar el aprendizaje supervisado de clasificación multiclase frente a alternativas metodológicas.

3.5 Tipo de datos y alcance

Tabla 1

Estructura de variables utilizada en IrisFlow

Variable	Tipo	Rol	Unidad	Descripción
Sepal.Length	Numérica continua	Predictora	cm	Longitud del sépal
Sepal.Width	Numérica continua	Predictora	cm	Ancho del sépal
Petal.Length	Numérica continua	Predictora	cm	Longitud del pétalo
Petal.Width	Numérica continua	Predictora	cm	Ancho del pétalo
Species	Categórica nominal	Objetivo	—	setosa, versicolor o virginica

Nota. *Elaboración propia a partir del dataset Iris cargado en el notebook F1_Definicion.ipynb.*

El alcance comprende definición del problema, control de integridad, análisis descriptivo, revisión de valores atípicos, exploración de relaciones lineales, normalización y justificación metodológica. Quedan expresamente fuera de Fase 1 la partición entrenamiento/prueba, el entrenamiento de modelos, el ajuste de hiperparámetros y la evaluación predictiva. Esta delimitación mantiene coherencia con el propósito de la fase y evita anticipar decisiones propias del modelamiento.

Dentro de KDD, el problema se inserta inicialmente en selección, preprocesamiento y transformación; la minería de datos/modelamiento queda definida como etapa posterior, mientras la interpretación de esta fase se limita a la evidencia exploratoria que sustenta las decisiones iniciales (Ruete, 2026c; Fayyad et al., 1996).

IV. Clasificación del tipo de aprendizaje

El enfoque seleccionado es aprendizaje supervisado de clasificación multiclase. La decisión no se basa en una preferencia algorítmica, sino en la correspondencia entre el problema formulado, la estructura de los datos y la variable objetivo. Species está disponible para las 150 observaciones y representa una categoría nominal con tres clases; por tanto, la salida esperada es una clase y no un valor continuo ni una estructura latente (Ruete, 2026b).

Tabla 2

Criterios que determinan el tipo de aprendizaje

Criterio	Evidencia en IrisFlow	Decisión metodológica
Variable objetivo	Especies disponible en todas las observaciones	Aprendizaje supervisado
Naturaleza de la salida	Categorica nominal con tres clases	Clasificación multiclase
Variables de entrada	Cuatro medidas morfológicas continuas	Predictores numéricos
Propósito analítico	Asignar una observación a una especie	Predicción de clase

Nota. La decisión se fundamenta en la disponibilidad de etiqueta, el tipo de variable objetivo y el resultado esperado.

La regresión no corresponde porque Species no es una variable cuantitativa continua. El aprendizaje no supervisado podría utilizarse como apoyo exploratorio si se ignorara la etiqueta y se buscaran agrupamientos morfológicos, pero no responde al objetivo principal de clasificación. El aprendizaje por refuerzo se descarta porque el dataset es estático y no contiene agente, estados, acciones ni recompensas. La comparación completa se presenta en el apartado VII.


V. Relación entre Machine Learning y metodología KDD

KDD corresponde a un proceso completo de descubrimiento de conocimiento y no se reduce a la ejecución de un algoritmo. Machine Learning se incorpora principalmente en la etapa de modelamiento/minería de datos, pero su validez depende de las decisiones realizadas previamente sobre selección, calidad y transformación de los datos. Esta relación es central en Fase 1, porque el modelamiento se proyecta, pero aún no se ejecuta (Fayyad et al., 1996; Ruete, 2026c).

Figura 1

Flujo KDD aplicado a IrisFlow

Proceso KDD aplicado a IrisFlow — Fase 1



Nota. Figura generada por el notebook. La etapa de modelamiento se incluye para ubicar el enfoque seleccionado dentro de KDD; no se ejecuta entrenamiento en Fase 1.

Tabla 3*Función de cada etapa KDD en IrisFlow*

Etapa KDD	Aplicación en IrisFlow	Función respecto del modelo
Selección	Iris, predictores morfológicos y Species.	Delimita las variables de entrada y la variable objetivo que estructuran el modelo de clasificación.
Preprocesamiento	Tipos de datos, faltantes, coincidencias, distribución de clases y atípicos.	Establece las condiciones de calidad que deben documentarse antes del ajuste de un modelo.
Transformación	Codificación exploratoria y normalización Min-Max.	Define representaciones numéricas para el análisis y preserva Species como variable nominal.
Modelamiento / minería de datos	Clasificación supervisada multiclase.	Corresponde a la etapa de ajuste del clasificador; el entrenamiento no se ejecuta en Fase 1.
Interpretación y evaluación	Síntesis de evidencia exploratoria.	Relaciona la evidencia analítica con el problema; en Fase 1 la interpretación se limita a resultados exploratorios.

Nota. *Elaboración propia a partir de Ruete (2026c), Fayyad et al. (1996) y la ejecución del notebook.*

VI. Notebook F1_Definición.ipynb

La formalización técnica se implementa en Semana1/notebook/F1_Definicion.ipynb. El notebook utiliza pandas para la manipulación tabular, scikit-learn para cargar Iris y aplicar MinMaxScaler, y scipy para los valores p de Pearson. Los metadatos del archivo registran Python 3.12.4. La ejecución almacenada contiene 22 celdas de código con conteos consecutivos del 1 al 22 y no presenta salidas de error (pandas development team, s. f.; scikit-learn developers, s. f.; Pedregosa et al., 2011).

El flujo computacional sigue la secuencia: selección del dataset - control de integridad - análisis descriptivo y atípicos - codificación exploratoria - correlación y valores p - normalización - comparación metodológica - inventario de evidencia. Las tablas y figuras incorporadas en el informe proceden de la ejecución almacenada y se conservan en Semana1/outputs y Semana1/figures, lo que permite rastrear cada resultado hasta su archivo de origen.

Correspondencia con los componentes requeridos. El notebook contiene la definición del problema de clasificación de Species; el objetivo general y los objetivos específicos del proyecto; la estructura del flujo de Fase 1; el código base para carga, control de integridad, análisis descriptivo, correlación, valores p, normalización y exportación de evidencia; y la correspondencia con el enfoque supervisado multiclase, sustentada en la existencia de una variable objetivo categórica conocida.

6.1 Control de integridad y distribución de la variable objetivo

Tabla 4

Control de integridad del dataset


Indicador	Resultado
Observaciones	150
Variables	5
Valores faltantes	0
Clases de Species	3
Combinación completa repetida respecto de una fila previa	1

Nota. Fuente: *Semana1/outputs/control_integridad.csv*.

El dataset presenta completitud total y una distribución de 50 observaciones por especie, equivalentes a 33,33 % para setosa, versicolor y virginica. Por tanto, la evidencia inicial no muestra desbalance de clases en la variable objetivo.

Figura 2

Distribución de la variable objetivo Species



Nota. Fuente: figura generada por el notebook a partir de las 150 observaciones de Iris.

Se identifican dos registros, con índices 101 y 142, cuyos valores coinciden en los cuatro predictores y en Species. La función `duplicated().sum()` contabiliza una repetición respecto de una fila previa; sin embargo, la ausencia de un identificador de unidad experimental impide establecer si ambos registros representan la misma observación física o mediciones independientes coincidentes. En Fase 1 se conservan y se documentan sin asumir duplicación de unidad experimental.

6.2 Estadística descriptiva y valores atípicos

Tabla 5

Resumen descriptivo de las variables predictoras


Variable	Media	DE	Mínimo	Máximo
Sepal.Length	5,843	0,828	4,3	7,9
Sepal.Width	3,057	0,436	2,0	4,4
Petal.Length	3,758	1,765	1,0	6,9
Petal.Width	1,199	0,762	0,1	2,5

Nota. Valores calculados sobre 150 observaciones; DE = desviación estándar. Fuente: *Semana1/outputs/resumen_descriptivo.csv*.

El criterio de Tukey ($1,5 \times \text{IQR}$) identifica cuatro valores atípicos relativos en Sepal.Width, con límites de 2,05 y 4,05, y no identifica atípicos en los otros tres predictores. Estos valores no se eliminan automáticamente, porque su condición estadística no constituye evidencia suficiente de error de medición (Ruede, 2026a).

Figura 3

Boxplot de las variables morfológicas




Nota. Fuente: figura generada por el notebook; los puntos fuera de los bigotes se documentan sin eliminación automática.

6.3 Correlación de Pearson y valores p

El análisis principal de Pearson se restringe a las cuatro variables predictoras continuas. La mayor asociación lineal se observa entre Petal.Length y Petal.Width ($r = 0,963$), seguida de Sepal.Length con Petal.Length ($r = 0,872$) y con Petal.Width ($r = 0,818$). Para Sepal.Length y Sepal.Width se obtiene $r = -0,118$ y $p = 0,152$; con $\alpha = 0,05$ no se rechaza $H_0: \rho = 0$. Los demás pares presentan valores p inferiores a 0,05. Estos resultados se interpretan de forma exploratoria y no se utilizan como criterio automático de selección de variables ni como evidencia causal.

Figura 4

Matriz de correlación de Pearson entre predictores



Nota. Fuente: *Semana1/outputs/correlacion_predictores.csv*. La inferencia se limita a predictores continuos.

El notebook genera adicionalmente una codificación temporal de Species (1 = setosa, 2 = versicolor, 3 = virginica) solo como apoyo exploratorio. Esta numeración se trata como identificador de clase y no como escala ordinal o variable continua, por lo que no se utiliza para inferencia sobre la variable objetivo.

6.4 Normalización e inventario de evidencia

La transformación Min-Max se aplica exclusivamente a los cuatro predictores. La verificación programática confirma mínimo 0 y máximo 1 para cada variable, mientras Species permanece categórica. En Fase 1 la transformación se utiliza con finalidad exploratoria sobre el conjunto completo; en una fase predictiva el escalador deberá ajustarse únicamente con el conjunto de entrenamiento para evitar que información del conjunto de prueba intervenga en el preprocesamiento.

Tabla 6

Verificación de la normalización Min-Max

Variable	Mínimo	Máximo
Sepal.Length	0,0	1,0
Sepal.Width	0,0	1,0
Petal.Length	0,0	1,0
Petal.Width	0,0	1,0

Nota. Fuente: *Semana1/outputs/verificacion_normalizacion.csv*.

La última celda del notebook registra el inventario de la evidencia generada por la ejecución y confirma la exportación del dataset, 14 archivos CSV y 5 figuras PNG. Los 22 conteos de ejecución son consecutivos y no existen salidas de error almacenadas, por lo que la evidencia incluida en el repositorio corresponde a una ejecución completa del flujo documentado.

VII. Comparación de enfoques

La selección metodológica se contrastó con aprendizaje no supervisado y aprendizaje por refuerzo utilizando como criterios la disponibilidad de etiqueta, el tipo de señal, el objetivo analítico y el resultado esperado. Esta comparación permite justificar la decisión adoptada y evita confundir clasificación con agrupamiento o con aprendizaje basado en interacción (Ruete, 2026b).

Tabla 7

Comparación de los tres tipos de aprendizaje

Enfoque	Definición operativa	Dato o señal	Ejemplo de uso	Evaluación para IrisFlow
Supervisado	Aprende relación entre predictores y salida conocida.	Observaciones con etiqueta.	Clasificar Species desde medidas morfológicas.	Seleccionado: existe etiqueta y la salida es categórica.
No supervisado	Busca estructura sin utilizar una etiqueta objetivo.	Observaciones sin etiqueta.	Agrupar flores por similitud ignorando Species.	Complementario: no responde al objetivo predictivo principal.
Por refuerzo	Aprende una política mediante interacción y recompensas.	Estados, acciones y recompensa.	Optimizar decisiones secuenciales en un entorno dinámico.	Descartado: datos estáticos, sin interacción ni recompensa.

Nota. Fuente: *Semana1/outputs/comparacion_enfoques.csv*; estructura alineada con ID1.3.

La decisión final es mantener aprendizaje supervisado de clasificación multiclase. El enfoque no supervisado puede aportar una exploración complementaria si se omite la etiqueta, pero no sustituye el objetivo principal de asignar una especie conocida. El aprendizaje por refuerzo se descarta porque el dataset es estático y carece de estados, acciones y recompensa.

VIII. Documentación del proceso

La documentación técnica organiza cada decisión de modo que pueda rastrearse desde el informe hacia el notebook y los archivos de evidencia del repositorio. La correspondencia se registra en *Semana1/docs/DECISIONES_TECNICAS.md* y *Semana1/docs/TRAZABILIDAD.md*; las evidencias analíticas se conservan en los CSV y figuras generados por la ejecución almacenada.

Repositorio GitHub: <https://github.com/edocontreras/mcdi504-machine-learning-1/tree/main>

Tabla 8*Decisiones técnicas y evidencia trazable*

Decisión	Evidencia	Fundamento
Especies se mantiene categórica.	estructura_variables.csv; iris_normalizado.csv.	Evita interpretar la clase nominal como magnitud.
Se conservan las 150 observaciones en Fase 1.	control_integridad.csv; registros_coincidentes.csv.	Los índices 101 y 142 presentan valores coincidentes en todas las variables; la procedencia de las unidades no puede determinarse sin identificador.
No se eliminan atípicos automáticamente.	atipicos_tukey.csv; boxplot_variables.png.	Un atípico estadístico no demuestra error de medición.
Pearson se restringe a predictores continuos.	correlacion_predictores.csv; pvalores_predictores.csv.	Evita inferencia sobre una codificación nominal arbitraria.
Min-Max solo en predictores.	iris_normalizado.csv; verificacion_normalizacion.csv.	Preserva Species y documenta una transformación compatible con futuros modelos sensibles a escala.
No se entrenan modelos.	F1_Definicion.ipynb; alcance del apartado 3.5.	Respeto el alcance de Fase 1 y la secuencia KDD.

Nota. Los CSV citados en la tabla se encuentran en Semana1/outputs/ y el notebook en Semana1/notebook/. La matriz completa de trazabilidad se mantiene en Semana1/docs/TRAZABILIDAD.md.

Durante la revisión del proceso se registraron tres cambios metodológicos realizados en Fase 1: (1) la coincidencia exacta de dos registros se documentó sin asumir que constituye necesariamente una duplicación de unidad experimental; (2) la inferencia de Pearson se restringió a predictores continuos y la codificación de Species quedó solo como exploración descriptiva; y (3) la normalización se aplicó exclusivamente a predictores. De manera separada, se mantuvo como decisión de alcance la exclusión de partición entrenamiento/prueba, entrenamiento de modelos, ajuste de hiperparámetros y métricas predictivas en Fase 1. Esta organización distingue los cambios metodológicos de la delimitación propia de la actividad y mantiene coherencia entre los datos, la evidencia computacional y la decisión de clasificación supervisada.

La correspondencia entre componentes es directa: el notebook produce los resultados, el repositorio conserva los CSV y figuras derivados, y el informe emplea las mismas denominaciones, valores y decisiones. La estructura permite verificar cada afirmación mediante una salida computacional identificable.

IX. Conclusiones

1. La definición del problema, el tipo de datos y la variable objetivo conducen de manera consistente a un enfoque de aprendizaje supervisado de clasificación multiclase. Species es una etiqueta nominal conocida para las 150 observaciones y el resultado esperado es la asignación de una de tres especies; por ello, ni regresión, ni clustering como tarea principal, ni aprendizaje por refuerzo responden al objetivo analítico.
2. La exploración inicial confirma una base de datos completa y balanceada, con cero valores faltantes y 50 observaciones por clase. Los registros de índices 101 y 142 presentan valores coincidentes en todas las variables y Sepal.Width contiene cuatro atípicos relativos según Tukey; ambas situaciones se documentan sin eliminación automática, porque la evidencia disponible no permite calificarlas por sí sola como errores de datos.
3. Las decisiones de transformación preservan la naturaleza del problema. Species se mantiene categórica, su codificación numérica se restringe a apoyo exploratorio, Pearson inferencial se aplica a predictores continuos y Min-Max transforma únicamente las variables de entrada. Estas decisiones reducen interpretaciones impropias y mantienen una separación clara entre preparación de datos y variable objetivo.
4. La relación con KDD queda establecida de forma explícita: Fase 1 cubre selección, preprocesamiento, transformación e interpretación de evidencia exploratoria; el modelamiento/minería de datos se define como una etapa posterior. La estructura del notebook y del repositorio permite reconstruir las decisiones y los resultados desde una misma ejecución.
5. La continuidad del proyecto se apoya en esta base documentada. Antes del modelamiento deberá definirse una regla explícita para el tratamiento de los registros coincidentes y para la partición de datos; las transformaciones dependientes de los datos deberán ajustarse sobre el conjunto de entrenamiento antes de comparar modelos de clasificación y evaluar su desempeño. Esta proyección mantiene la secuencia metodológica definida por KDD.

X. Uso de fuentes, citación y referencias

Las decisiones conceptuales y técnicas del informe se sustentan en tres fuentes del material docente, dos fuentes de documentación técnica oficial y dos fuentes académicas complementarias. Las citas se integran en los apartados donde justifican la clasificación del aprendizaje, la relación con KDD, el tratamiento exploratorio y la implementación computacional.

Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37–54.

pandas development team. (s. f.). *pandas documentation*. Recuperado el 7 de agosto de 2026, de <https://pandas.pydata.org/docs/>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Ruete, D. (2026a). *Fase 1: estadística descriptiva, correlación y normalización de datos* [Apunte]. Universidad Andrés Bello.

Ruete, D. (2026b). *Introducción al machine learning* [Apunte]. Universidad Andrés Bello.

Ruete, D. (2026c). *Relación entre ML y metodología KDD* [Apunte]. Universidad Andrés Bello.

scikit-learn developers. (s. f.). *scikit-learn documentation*. Recuperado el 7 de agosto de 2026, de <https://scikit-learn.org/stable/documentation.html>

XI. Anexos

Los anexos reúnen resultados complementarios derivados directamente de la ejecución del notebook. Su función es respaldar la trazabilidad del análisis sin duplicar innecesariamente las evidencias principales presentadas en el cuerpo del informe.

Anexo A. Registros con valores coincidentes en todas las variables

Tabla A1

Registros con valores coincidentes en los predictores y en Species

Fila	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
101	5,8	2,7	5,1	1,9	virginica
142	5,8	2,7	5,1	1,9	virginica

Nota. Fuente: *Semana1/outputs/registros_coincidentes.csv*. La coincidencia no permite determinar por sí sola si existe duplicación de unidad experimental.

Anexo B. Revisión de valores atípicos mediante Tukey

Tabla A2

Límites y número de atípicos por variable


Variable	Límite inferior	Límite superior	N atípicos
Sepal.Length	3,15	8,35	0
Sepal.Width	2,05	4,05	4
Petal.Length	-3,65	10,35	0
Petal.Width	-1,95	4,05	0

Nota. Fuente: *Semana1/outputs/atipicos_tukey.csv*.

Anexo C. Valores p de Pearson entre predictores

Figura A1

Mapa de valores p de Pearson



Nota. Fuente: *Semana1/outputs/pvalores_predictores.csv*. La diagonal se omite porque no corresponde contrastar una variable consigo misma.

Anexo D. Evidencia reproducible del repositorio

La ejecución de *F1_Definicion.ipynb* genera y conserva 14 archivos CSV y 5 figuras PNG, además de *iris_original.csv*. Los archivos CSV son: *atipicos_tukey.csv*, *codificacion_especies.csv*, *comparacion_enfoques.csv*, *control_integridad.csv*, *correlacion_predictores.csv*, *correlacion_especies_exploratoria.csv*, *distribucion_clases.csv*, *estructura_variables.csv*, *iris_normalizado.csv*, *kdd_aplicado.csv*, *pvalores_predictores.csv*, *registros_coincidentes.csv*, *resumen_descriptivo.csv* y *verificacion_normalizacion.csv*. La matriz informe–notebook–repositorio se mantiene en *Semana1/docs/TRAZABILIDAD.md*.

La organización permite verificar que las afirmaciones del informe proceden de salidas concretas del notebook y que cada resultado complementario conserva una ruta explícita dentro del repositorio.