

**MCDI504**

**MACHINE LEARNING I**

**AVANCE DEL PROYECTO — FASE 2:  
BÚSQUEDA Y RECOPIACIÓN DE  
INFORMACIÓN**

Nombre integrante/s: Luis Díaz Giral, Gonzalo Bouldres y Eduardo Contreras

Curso: MCDI504 - Machine Learning I

Fecha: 14 de agosto de 2026

Docente: Dr. David Ruete Zúñiga    Grupo: 6

## APARTADOS

- I. Portada e índice
- II. Introducción y contextualización
- III. Descripción del conjunto de datos y preprocesamiento
- IV. Modelo de regresión lineal simple
- V. Modelo de árboles de decisión para regresión
- VI. Modelo de redes neuronales para regresión
- VII. Evaluación de modelos de regresión
- VIII. Comparación de modelos
- IX. Notebook F2\_Regresion.ipynb y documentación del proceso
- X. Conclusiones
- XI. Uso de fuentes, citación y referencias
- XII. Anexos

## II. Introducción y contextualización

El proyecto se desarrolla como un problema de aprendizaje supervisado de regresión, ya que la variable objetivo MedHouseVal es numérica y continua. El caso utiliza California Housing, un conjunto disponible mediante scikit-learn que reúne variables socioeconómicas, habitacionales y geográficas de distritos censales de California. El propósito predictivo consiste en estimar el valor mediano de las viviendas a partir de información observada en cada distrito (James et al., 2023; Pedregosa et al., 2011).

La situación de análisis requiere comparar alternativas con distinto grado de flexibilidad: una regresión lineal simple como referencia interpretable, un árbol de decisión capaz de representar umbrales e interacciones y una red neuronal MLP orientada a relaciones no lineales más complejas. El desempeño se evalúa en observaciones reservadas para prueba mediante MSE, RMSE y  $R^2$ , evitando juzgar los modelos con los mismos datos utilizados para entrenarlos (Ruete, 2026d).

### 2.1 Objetivo analítico

Preparar el conjunto de datos, implementar y evaluar tres modelos de regresión supervisada y, a partir de evidencia obtenida en Python, identificar la alternativa con mejor desempeño predictivo, discutir sus ventajas y limitaciones y establecer una recomendación técnica para la continuidad del proyecto.

| Elemento            | Aplicación en el caso                                                      |
|---------------------|----------------------------------------------------------------------------|
| Contexto            | Predicción del valor mediano de viviendas por distrito censal.             |
| Datos               | 20.640 observaciones, ocho predictores numéricos y una respuesta continua. |
| Variable objetivo   | MedHouseVal, expresada en cientos de miles de dólares.                     |
| Tipo de aprendizaje | Regresión supervisada.                                                     |
| Decisión            | Comparar desempeño, interpretabilidad y riesgo de sobreajuste.             |

## III. Descripción del conjunto de datos y preprocesamiento

### 3.1 Descripción general del dataset

California Housing contiene 20.640 registros. En la ejecución analizada, todas las variables se cargaron como numéricas y no se detectaron valores faltantes. La variable objetivo MedHouseVal se mantiene sin escalamiento; los predictores se procesan de acuerdo con el pipeline descrito a continuación.

| Variable    | Rol        | Descripción                                                               |
|-------------|------------|---------------------------------------------------------------------------|
| MedInc      | Predictora | Ingreso mediano del distrito, expresado en decenas de miles de dólares.   |
| HouseAge    | Predictora | Edad media de las viviendas del distrito.                                 |
| AveRooms    | Predictora | Número medio de habitaciones por vivienda.                                |
| AveBedrms   | Predictora | Número medio de dormitorios por vivienda.                                 |
| Population  | Predictora | Población del distrito.                                                   |
| AveOccup    | Predictora | Número medio de ocupantes por hogar.                                      |
| Latitude    | Predictora | Latitud del distrito.                                                     |
| Longitude   | Predictora | Longitud del distrito.                                                    |
| MedHouseVal | Objetivo   | Valor mediano de las viviendas, expresado en cientos de miles de dólares. |

### 3.2 Valores faltantes y selección de variables

El control de valores faltantes produjo cero nulos en las nueve columnas. Por esta razón no se aplicó imputación. La ausencia de imputación se considera una decisión de preprocesamiento documentada, no la omisión del control de calidad.

Para la regresión lineal simple se necesitó un único predictor. La selección se realizó usando exclusivamente el conjunto de entrenamiento: MedInc presentó la mayor correlación de Pearson absoluta con MedHouseVal, con  $r=0.690647$ . Para árbol y MLP se conservaron los ocho predictores, dado que esta fase no incorpora una etapa formal de selección multivariable de características.

### 3.3 Partición entrenamiento/prueba y estandarización

La base se dividió en 80% para entrenamiento y 20% para prueba con `random_state=42`. Esto produjo 16.512 observaciones de entrenamiento y 4.128 observaciones de prueba. El conjunto de prueba permaneció fuera de la selección del predictor y del ajuste de `StandardScaler`.

`StandardScaler` se ajustó exclusivamente con `X_train` y posteriormente transformó `X_train` y `X_test`. Este procedimiento evita filtración de información desde prueba. El escalamiento es particularmente relevante para el MLP por su entrenamiento basado en optimización; se mantuvo la misma representación estandarizada para los modelos comparados dentro del pipeline (Ruete, 2026c; scikit-learn Developers, 2026d; scikit-learn Developers, 2026e).

### 3.4 Análisis exploratorio inicial




Figura 1. Distribución de MedHouseVal y matriz de correlación del conjunto de datos.

El análisis exploratorio muestra una distribución amplia de MedHouseVal y relaciones lineales de distinta intensidad. MedInc es el predictor con mayor asociación lineal con la respuesta; además, Latitude y Longitude presentan una correlación elevada entre sí, lo que evidencia estructura geográfica relevante. Estas observaciones se utilizan para describir los datos, mientras que la elección del predictor simple se basa únicamente en entrenamiento.

## IV. Modelo de regresión lineal simple

La regresión lineal simple modela la relación entre una variable predictora y una respuesta continua mediante una recta. En esta implementación se utiliza MedInc como único predictor, seleccionado en entrenamiento, y su versión estandarizada como entrada del modelo LinearRegression (Ruefe, 2026a; scikit-learn Developers, 2026a).

```
modelo_lineal_simple = LinearRegression()
modelo_lineal_simple.fit(X_train_simple, y_train)
pred_simple_test = modelo_lineal_simple.predict(X_test_simple)
```

| Elemento       | Resultado            |
|----------------|----------------------|
| Predictor      | MedInc estandarizado |
| Intercepto     | 2,071947             |
| Coefficiente   | 0,798520             |
| MSE            | 0,709116             |
| RMSE           | 0,842090             |
| R <sup>2</sup> | 0,458859             |




Figura 2. Regresión lineal simple con MedInc sobre el conjunto de prueba.

El  $R^2$  de 0.458859 indica que el modelo explica aproximadamente 45.89% de la variabilidad observada en prueba. El RMSE de 0.842090 equivale a un error típico aproximado de USD 84,209. Como MedInc fue estandarizado, el coeficiente de 0.798520 representa el cambio esperado en MedHouseVal ante un aumento de una desviación estándar de MedInc. El gap de  $R^2$  entre entrenamiento y prueba es 0.018134, por lo que no se observa una diferencia amplia entre ambos subconjuntos.

## V. Modelo de árboles de decisión para regresión

DecisionTreeRegressor divide recursivamente el espacio de predictores y genera una predicción constante en cada hoja terminal. Se utiliza `max_depth=5` como mecanismo de pre-poda para limitar complejidad y reducir la posibilidad de memorizar ruido (Ruete, 2026b; scikit-learn Developers, 2026b).

| Parámetro         | Valor                               | Lectura técnica                                     |
|-------------------|-------------------------------------|-----------------------------------------------------|
| criterion         | squared_error                       | Criterio de reducción del error cuadrático.         |
| splitter          | best                                | Estrategia de búsqueda de la mejor división.        |
| max_depth         | 5                                   | Limita la profundidad máxima del árbol.             |
| min_samples_split | 2                                   | Mínimo de observaciones para dividir un nodo.       |
| min_samples_leaf  | 1                                   | Mínimo de observaciones por hoja.                   |
| random_state      | 42                                  | Fija la reproducibilidad del ajuste.                |
| Preprocesamiento  | StandardScaler ajustado con X_train | Representación de entrada utilizada en el pipeline. |
| Objetivo          | MedHouseVal                         | Variable continua a predecir.                       |

En prueba, el árbol obtuvo  $MSE=0.524515$ ,  $RMSE=0.724234$  y  $R^2=0.599732$ . Frente a la regresión lineal simple, reduce el MSE en 26.03% y eleva  $R^2$  en 0.140873 puntos. El gap de  $R^2$  entrenamiento-prueba fue 0.037947; la profundidad limitada contribuye a mantener una complejidad moderada.




Figura 3. Valores observados versus predichos y residuos del árbol de decisión.

## VI. Modelo de redes neuronales para regresión

MLPRegressor utiliza capas, pesos, sesgos y funciones de activación no lineales. La configuración emplea una capa oculta de 100 neuronas, ReLU, optimizador Adam, regularización L2 mediante alpha y early stopping con validación interna. El escalamiento de las entradas es relevante para la estabilidad del entrenamiento (Ruete, 2026c; scikit-learn Developers, 2026c).

| Hiperparámetro      | Valor                               |
|---------------------|-------------------------------------|
| hidden_layer_sizes  | (100,)                              |
| activation          | relu                                |
| solver              | adam                                |
| alpha               | 0.0001                              |
| learning_rate_init  | 0.001                               |
| max_iter            | 500                                 |
| early_stopping      | True                                |
| validation_fraction | 0.1                                 |
| n_iter_no_change    | 10                                  |
| random_state        | 42                                  |
| Preprocesamiento    | StandardScaler ajustado con X_train |
| Objetivo            | MedHouseVal                         |

El entrenamiento finalizó en 153 iteraciones. El mejor score de validación interna registrado fue 0.767217 en la iteración 147. En prueba, el MLP obtuvo MSE=0.301732, RMSE=0.549301 y  $R^2=0.769742$ . El gap de  $R^2$  entrenamiento-prueba fue 0.020083.




Figura 4. Evolución de la función de pérdida durante el entrenamiento del MLP.



## VII. Evaluación de modelos de regresión

MSE, RMSE y  $R^2$  se calcularon sobre las mismas 4.128 observaciones de prueba. MSE penaliza con mayor intensidad los errores grandes; RMSE vuelve a las unidades de MedHouseVal; y  $R^2$  mide el desempeño respecto de una predicción basada en la media. Las métricas deben interpretarse de forma conjunta (Ruete, 2026d; James et al., 2023).

| Modelo                           | MSE      | RMSE     | $R^2$    |
|----------------------------------|----------|----------|----------|
| Regresión lineal simple (MedInc) | 0,709116 | 0,842090 | 0,458859 |
| Árbol de decisión                | 0,524515 | 0,724234 | 0,599732 |
| Red neuronal MLP                 | 0,301732 | 0,549301 | 0,769742 |

Tabla 1. Métricas de desempeño sobre el conjunto de prueba.




Figura 5. Comparación visual de MSE y  $R^2$  entre los tres modelos principales.

El MLP presenta simultáneamente el menor MSE (0.301732), el menor RMSE (0.549301) y el mayor  $R^2$  (0.769742). Respecto de la regresión simple, reduce MSE en 57.45% y RMSE en 34.77%; respecto del árbol, las reducciones son 42.47% y 24.15%, respectivamente. Esta lectura se limita a la partición y configuración evaluadas y no implica que un modelo sea universalmente superior.

## VIII. Comparación de modelos

La comparación integra desempeño predictivo, interpretabilidad y complejidad. La regresión lineal simple ofrece la lectura más directa; el árbol representa reglas y umbrales; el MLP ofrece mayor flexibilidad a costa de menor interpretabilidad. La decisión analítica se fundamenta en la evidencia de prueba y en las características de cada familia de modelos.

| Modelo                  | Fortalezas                                                | Limitaciones                                                    | Lectura del resultado          |
|-------------------------|-----------------------------------------------------------|-----------------------------------------------------------------|--------------------------------|
| Regresión lineal simple | Alta interpretabilidad y línea base directa.              | Un predictor y estructura estrictamente lineal.                 | MSE=0.709116; $R^2=0.458859$ . |
| Árbol de decisión       | Captura umbrales e interacciones; reglas comprensibles.   | Puede sobreajustar si aumenta excesivamente la profundidad.     | MSE=0.524515; $R^2=0.599732$ . |
| Red neuronal MLP        | Mayor flexibilidad para relaciones no lineales complejas. | Menor interpretabilidad y mayor sensibilidad a hiperparámetros. | MSE=0.301732; $R^2=0.769742$ . |

### 8.1 Comparación complementaria con ocho predictores

Para separar el efecto de usar un solo predictor en la regresión simple, se mantuvo una comparación complementaria con regresión lineal multivariable, árbol y MLP utilizando los mismos ocho predictores estandarizados y el mismo conjunto de prueba. La regresión multivariable obtuvo MSE=0.555892, RMSE=0.745581 y  $R^2=0.575788$ ; el árbol mantuvo MSE=0.524515 y  $R^2=0.599732$ ; y el MLP mantuvo MSE=0.301732 y  $R^2=0.769742$ . El MLP conserva el mejor desempeño en esta comparación, por lo que su ventaja no depende únicamente de contrastarlo con una regresión simple de un predictor.

### 8.2 Elección analítica

Bajo la configuración evaluada, se selecciona el MLP como candidato predictivo principal para la continuidad del proyecto. La regresión lineal se conserva como referencia interpretable y el árbol como alternativa intermedia. La selección se considera preliminar: fases posteriores deben utilizar validación cruzada y ajuste sistemático de hiperparámetros antes de establecer una configuración definitiva.

## IX. Notebook F2\_Regresion.ipynb y documentación del proceso

El notebook constituye la evidencia técnica del proceso y fue ejecutado de inicio a fin sin errores almacenados. La ejecución registra versiones del entorno y exporta las tablas y figuras utilizadas en este informe. La estructura del repositorio mantiene la continuidad con Semana 1 mediante carpetas equivalentes para datos, documentación, figuras, informe, notebook y outputs.

### 9.1 Entorno de ejecución

| Componente   | Versión |
|--------------|---------|
| Python       | 3.12.4  |
| NumPy        | 1.26.4  |
| pandas       | 2.2.2   |
| scikit-learn | 1.4.2   |
| Matplotlib   | 3.8.4   |

### 9.2 Trazabilidad de evidencias

| Etapas             | Archivo derivado                                                   | Sección del informe |
|--------------------|--------------------------------------------------------------------|---------------------|
| Variables y nulos  | diccionario_variables.csv; control_nulos.csv                       | III                 |
| Partición y scaler | dimensiones_split.csv;<br>parametros_standard_scaler.csv           | III                 |
| Regresión simple   | ficha_tecnica_regresion_lineal_simple.csv;<br>metricas_modelos.csv | IV, VII             |
| Árbol              | ficha_tecnica_arbol.csv; metricas_modelos.csv                      | V, VII              |
| MLP                | ficha_tecnica_mlp.csv;<br>mlp_validation_scores.csv                | VI, VII             |
| Predicciones       | predicciones_test.csv                                              | VII, XII            |
| Generalización     | diagnostico_generalizacion.csv                                     | IV-VIII, XII        |
| Comparación        | orden_modelos.csv; figuras comparativas                            | VIII                |

### 9.3 Secuencia principal del notebook

- Carga y descripción de California Housing.
- Control de valores faltantes y análisis exploratorio.
- Partición entrenamiento/prueba y selección del predictor simple.
- Ajuste de StandardScaler exclusivamente con entrenamiento.
- Entrenamiento de regresión lineal simple, árbol y MLP.
- Cálculo de MSE, RMSE y  $R^2$  sobre prueba.
- Exportación de predicciones, diagnósticos y figuras.

La documentación del repositorio incluye README, descripción de datos, decisiones técnicas, fuentes, trazabilidad y requirements.txt. La primera carga de California Housing puede requerir conexión a Internet si el dataset no se encuentra en la caché local.

## X. Conclusiones

---

La Fase 2 permitió desarrollar un pipeline reproducible de regresión supervisada para California Housing. El flujo incorpora descripción del dataset, control de nulos, selección de variables, partición entrenamiento/prueba, estandarización aprendida solo con entrenamiento y evaluación sobre un conjunto de prueba independiente.

La regresión lineal simple alcanzó  $MSE=0.709116$ ,  $RMSE=0.842090$  y  $R^2=0.458859$ ; el árbol obtuvo  $MSE=0.524515$ ,  $RMSE=0.724234$  y  $R^2=0.599732$ ; y el MLP obtuvo  $MSE=0.301732$ ,  $RMSE=0.549301$  y  $R^2=0.769742$ . El orden de desempeño es consistente en las tres métricas: MLP, árbol y regresión lineal simple.

El MLP se propone como alternativa predictiva principal bajo la configuración evaluada, mientras que la regresión lineal y el árbol se conservan como referencias de interpretación y contraste. Para la continuidad se recomienda validación cruzada, búsqueda sistemática de hiperparámetros, análisis formal de residuos y comparación con Random Forest y SVR, manteniendo el conjunto de prueba fuera del proceso de tuning.

En términos de toma de decisiones, la evidencia de esta fase permite priorizar un modelo con mayor desempeño predictivo sin perder el valor de modelos más interpretables. La siguiente fase debería determinar si la ventaja del MLP se mantiene al incorporar validación más robusta y ajuste de hiperparámetros.

## XI. Uso de fuentes, citación y referencias

Las decisiones conceptuales y técnicas del informe se fundamentan en material docente de la asignatura, documentación oficial de scikit-learn y literatura académica complementaria. Las referencias listadas a continuación corresponden a fuentes citadas en el desarrollo.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: With applications in Python*. Springer. <https://doi.org/10.1007/978-3-031-38747-0>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830. <https://jmlr.org/papers/v12/pedregosa11a.html>

Ruete, D. (2026a). Regresión lineal simple, polinomial y multivariable [Apunte]. Universidad Andrés Bello.

Ruete, D. (2026b). Regresión con árboles de decisión [Apunte]. Universidad Andrés Bello.

Ruete, D. (2026c). Regresión con redes neuronales artificiales [Apunte]. Universidad Andrés Bello.

Ruete, D. (2026d). Evaluación de modelos de regresión [Apunte]. Universidad Andrés Bello.

scikit-learn Developers. (2026a). LinearRegression. scikit-learn. [https://scikit-learn.org/stable/modules/generated/sklearn.linear\\_model.LinearRegression.html](https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html)

scikit-learn Developers. (2026b). DecisionTreeRegressor. scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeRegressor.html>

scikit-learn Developers. (2026c). MLPRegressor. scikit-learn. [https://scikit-learn.org/stable/modules/generated/sklearn.neural\\_network.MLPRegressor.html](https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPRegressor.html)

scikit-learn Developers. (2026d). train\_test\_split. scikit-learn. [https://scikit-learn.org/stable/modules/generated/sklearn.model\\_selection.train\\_test\\_split.html](https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html)

scikit-learn Developers. (2026e). StandardScaler. scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>

## XII. Anexos

### Anexo A. Primeras cinco observaciones de prueba y predicciones

| y real   | Lineal simple | Lineal multivariable | Árbol    | MLP      |
|----------|---------------|----------------------|----------|----------|
| 0,477000 | 1,149589      | 0,719123             | 1,168573 | 0,374690 |
| 0,458000 | 1,506069      | 1,764017             | 1,271581 | 1,174805 |
| 5,000010 | 1,903937      | 2,709659             | 3,199582 | 4,754145 |
| 2,186000 | 2,850594      | 2,838926             | 2,204763 | 2,547741 |
| 2,780000 | 2,006633      | 2,604657             | 1,642797 | 2,916866 |

### Anexo B. Comparación entrenamiento/prueba

| Modelo                         | RMSE train | RMSE test | R <sup>2</sup> train | R <sup>2</sup> test | Gap R <sup>2</sup> |
|--------------------------------|------------|-----------|----------------------|---------------------|--------------------|
| Regresión lineal simple        | 0,836149   | 0,842090  | 0,476993             | 0,458859            | 0,018134           |
| Regresión lineal multivariable | 0,719676   | 0,745581  | 0,612551             | 0,575788            | 0,036763           |
| Árbol de decisión              | 0,695948   | 0,724234  | 0,637679             | 0,599732            | 0,037947           |
| Red neuronal MLP               | 0,530054   | 0,549301  | 0,789825             | 0,769742            | 0,020083           |

### Anexo C. Diagnóstico gráfico del modelo MLP




Figura A1. Valores observados versus predichos y residuos del MLP.

Los anexos se derivan directamente de la ejecución de F2\_Regresion.ipynb y sus archivos CSV. Las tablas y figuras del informe utilizan la misma corrida de entrenamiento y prueba, con random\_state=42.