

MCDI504

MACHINE LEARNING I

EVALUACIÓN SUMATIVA 2

INFORME FINAL DE PROYECTO - FASES 2 Y 3

REGRESIÓN Y CLASIFICACIÓN SUPERVISADA

Propósito

Integrar la evidencia de regresión supervisada de la Fase 2 y la clasificación supervisada mediante redes neuronales de la Fase 3, con resultados reproducibles, comparación técnica y fundamentación de decisiones.

Dato	Identificación
Integrantes	Luis Díaz Giral, Gonzalo Bouldres y Eduardo Contreras
Curso	MCDI504 - Machine Learning I
Docente	Dr. David Ruete Zúñiga
Semana	3
Evaluación	Sumativa 2
Fecha	19 de agosto de 2026
Grupo	6

I. Portada e índice

La estructura reproduce los apartados exigidos en la evaluación y mantiene correspondencia directa entre informe, notebook, tablas, figuras y repositorio.

II. Descripción del conjunto de datos y preparación analítica para regresión supervisada.....	3
III. Implementación del modelo de regresión supervisada.....	5
IV. Ajuste de hiperparámetros del modelo de regresión.....	6
V. Evaluación del desempeño mediante métricas de regresión.....	8
VI. Comparación técnica entre modelos de regresión.....	9
VII. Descripción del conjunto de datos y preparación para clasificación.....	10
VIII. Análisis exploratorio inicial del conjunto de datos.....	11
IX. Notebook F3_RedesNeuronales.ipynb y documentación del proceso.....	13
X. Red neuronal con una capa oculta.....	14
XI. Red neuronal con dos capas ocultas.....	15
XII. Red neuronal con tres capas ocultas.....	16
XIII. Desempeño de redes neuronales.....	17
XIV. Comparación de arquitecturas de redes neuronales.....	18
XV. Conclusiones.....	20
XVI. Uso de fuentes, citación y referencias.....	21
XVII. Anexos.....	22

II. Descripción del conjunto de datos y preparación analítica para regresión supervisada

2.1 Dataset y objetivo predictivo

La fase de regresión utiliza California Housing con 20.640 observaciones, ocho predictores numéricos y MedHouseVal como variable objetivo continua. El problema es estimar el valor mediano de la vivienda por distrito a partir de variables socioeconómicas, habitacionales y geográficas. La formulación corresponde a regresión supervisada porque la respuesta es cuantitativa continua (James et al., 2023).

Variable	Rol	Descripción
MedInc	Predictora	Ingreso mediano del grupo censal.
HouseAge	Predictora	Edad mediana de las viviendas.
AveRooms	Predictora	Promedio de habitaciones por hogar.
AveBedrms	Predictora	Promedio de dormitorios por hogar.
Population	Predictora	Población del grupo censal.
AveOccup	Predictora	Ocupación media por hogar.
Latitude	Predictora	Latitud.
Longitude	Predictora	Longitud.
MedHouseVal	Objetivo	Variable continua a predecir.

Tabla 1. Variables utilizadas en regresión.

2.2 Calidad, selección y partición

El control de calidad registró cero valores faltantes y cero filas duplicadas. Se separaron 16.512 observaciones para entrenamiento y 4.128 para prueba (80/20; random_state=42). La selección del predictor para la regresión lineal simple se realizó exclusivamente sobre entrenamiento: MedInc presentó la mayor correlación absoluta con MedHouseVal ($r=0,690647$).

StandardScaler se ajustó únicamente con el conjunto de entrenamiento y luego se aplicó a prueba para los modelos que utilizan escalamiento. El árbol de decisión se entrenó con las variables en su escala original. Esta separación evita que estadísticas aprendidas desde el test influyan en el ajuste del modelo.




Figura 1. Distribución de MedHouseVal.




Figura 2. Correlaciones con MedHouseVal calculadas únicamente en entrenamiento.

III. Implementación del modelo de regresión supervisada

Para ID2.1 se implementaron regresión lineal simple y regresión lineal multivariable mediante LinearRegression. Adicionalmente se entrenaron un árbol de decisión y un MLPRegressor para disponer de modelos no lineales comparables. El árbol inicial se utiliza como modelo sujeto a ajuste en la sección IV, porque sus hiperparámetros estructurales permiten controlar explícitamente la complejidad.

Modelo	Configuración inicial
Regresión lineal simple	predictor=MedInc; StandardScaler ajustado con entrenamiento
Regresión lineal multivariable	8 predictores; StandardScaler ajustado con entrenamiento
Árbol inicial	criterion=squared_error; max_depth=5; min_samples_split=2; min_samples_leaf=1; random_state=42
MLP regresión	hidden_layer_sizes=(100,); activation=relu; solver=adam; alpha=0.0001; learning_rate_init=0.001; early_stopping=True; max_iter=500; random_state=42

Tabla 2. Configuración inicial de los modelos de regresión.

Modelo	MSE test	RMSE test	R ² test
Regresión lineal simple	0.709116	0.842090	0.458859
Regresión lineal multivariable	0.555892	0.745581	0.575788
Árbol inicial	0.524515	0.724234	0.599732
MLP regresión	0.301732	0.549301	0.769742

Tabla 3. Resultados iniciales de regresión antes del ajuste del árbol.

La regresión lineal multivariable mejora respecto de la regresión simple, pero los modelos no lineales presentan menores errores. El MLPRegressor constituye la mejor referencia predictiva inicial; el árbol se conserva como modelo ajustable e interpretable mediante reglas.

IV. Ajuste de hiperparámetros del modelo de regresión

El ajuste se realizó mediante GridSearchCV con validación cruzada KFold de cinco particiones, shuffle=True y random_state=42. El conjunto de prueba permaneció aislado durante toda la búsqueda. Se evaluaron 72 combinaciones de max_depth, min_samples_split y min_samples_leaf, utilizando neg_root_mean_squared_error como scorer; para la interpretación se reporta RMSE positivo de validación. Esta estrategia es consistente con la recomendación de seleccionar hiperparámetros sin utilizar el test (Universidad Andrés Bello, 2026; scikit-learn Developers, 2026b).

Hiperparámetro	Valores evaluados
max_depth	3, 5, 7, 9, 12, None
min_samples_split	2, 5, 10
min_samples_leaf	1, 2, 5, 10
Validación	5 folds dentro de entrenamiento
Criterio	Menor RMSE medio de validación

Tabla 4. Espacio de búsqueda del árbol.

max_depth	min_split	min_leaf	RMSE CV	Rank
12	2	10	0.618781	1
12	5	10	0.618781	1
12	10	10	0.618781	1
None	2	10	0.619904	4
None	5	10	0.619904	4
None	10	10	0.619904	4
9	2	10	0.633009	7
9	5	10	0.633009	7

Tabla 5. Configuraciones mejor posicionadas por validación cruzada.




Figura 3. Mejores configuraciones del árbol según RMSE medio de validación cruzada.

La configuración seleccionada fue `max_depth=12`, `min_samples_leaf=10` y `min_samples_split=2`. Las tres primeras combinaciones empatan porque, con `min_samples_leaf=10`, los valores 2, 5 y 10 de `min_samples_split` no alteraron las particiones resultantes en esta región de la búsqueda.

Modelo	MSE test	RMSE test	R ² test	Gap R ²
Árbol inicial	0.524515	0.724234	0.599732	0.037947
Árbol ajustado	0.363096	0.602575	0.722914	0.115042

Tabla 6. Efecto del ajuste sobre el árbol de decisión.

El tuning redujo MSE en 30.77% y RMSE en 16.80%, mientras R^2 aumentó en 0.123182. La mejora confirma que la configuración inicial no era óptima. Sin embargo, el gap R^2 train-test del árbol ajustado aumenta a 0.115042, por lo que la mejora de prueba debe analizarse junto con su mayor diferencia respecto del ajuste observado en entrenamiento.

V. Evaluación del desempeño mediante métricas de regresión

La comparación cuantitativa se realiza sobre el mismo conjunto de prueba utilizando MSE, RMSE y R^2 . MSE penaliza de forma cuadrática los errores grandes, RMSE expresa el error en la escala de la variable objetivo y R^2 resume la proporción de variabilidad explicada respecto de la referencia basada en la media (James et al., 2023).

Modelo	MSE	RMSE	R^2	Gap R^2
Regresión lineal simple	0.709116	0.842090	0.458859	0.018134
Regresión lineal multivariable	0.555892	0.745581	0.575788	0.036763
Árbol inicial	0.524515	0.724234	0.599732	0.037947
MLP regresión	0.301732	0.549301	0.769742	0.020083
Árbol ajustado	0.363096	0.602575	0.722914	0.115042

Tabla 7. Evaluación final de regresión.




Figura 4. Comparación de RMSE y R^2 en el conjunto de prueba.

El MLPRegressor obtiene el menor RMSE (0.549301) y el mayor R^2 (0.769742). Además, su gap R^2 train-test (0.020083) es menor que el del árbol ajustado (0.115042). Por tanto, la evidencia de esta corrida favorece al MLP como modelo predictivo de regresión, mientras el árbol ajustado queda como alternativa no lineal más interpretable.

VI. Comparación técnica entre modelos de regresión

Modelo	Fortaleza	Limitación	Lectura técnica
Regresión lineal simple	Alta interpretabilidad y línea base transparente.	Solo utiliza MedInc y supone relación lineal.	Menor desempeño de prueba; útil como referencia.
Regresión lineal multivariable	Integra los ocho predictores con interpretación lineal.	No captura con flexibilidad interacciones no lineales.	Mejora frente a la simple, pero queda bajo árbol/MLP.
Árbol ajustado	Captura umbrales e interacciones y mejora tras tuning.	Mayor gap train-test después del ajuste.	Alternativa no lineal interpretable; no supera al MLP.
MLP regresión	Menor RMSE, mayor R^2 y gap reducido.	Menor interpretabilidad y mayor dependencia de hiperparámetros.	Modelo predictivo seleccionado en la corrida.

Tabla 8. Comparación técnica de modelos de regresión.

Decisión de regresión

Seleccionar MLPRegressor como modelo predictivo principal bajo la evidencia disponible. Mantener el árbol ajustado como alternativa interpretable y la regresión lineal como referencia. La selección se fundamenta en desempeño de prueba y brecha train-test, no en una única métrica.

VII. Descripción del conjunto de datos y preparación para clasificación

La clasificación utiliza Titanic con 891 observaciones y 15 columnas originales. La variable objetivo survived está codificada como 0=no sobrevivió y 1=sobrevivió. Se seleccionan siete predictores originales: pclass, age, sibsp, parch, fare, sex y embarked.

Variable	Rol/decisión
survived	Objetivo binario
pclass	Predictora ordinal (tratada numéricamente)
age	Predictora numérica continua
sibsp	Predictora numérica discreta
parch	Predictora numérica discreta
fare	Predictora numérica continua
sex	Predictora categórica binaria
embarked	Predictora categórica nominal
class	Excluida: redundante con pclass
who	Excluida: derivada de sex/age
adult_male	Excluida: derivada de sex/age
deck	Excluida: alta ausencia
embark_town	Excluida: redundante con embarked
alive	Excluida: fuga de información respecto de survived
alone	Excluida: derivada de sibsp/parch

Tabla 9. Selección de variables y exclusiones.

alive se excluye por fuga directa de información respecto de survived; class y embark_town por redundancia; who, adult_male y alone por ser variables derivadas; y deck por alta ausencia. Se detectaron 107 filas exactamente repetidas considerando las 15 columnas. Se conservaron porque el dataset no contiene identificador único de pasajero y la coincidencia de atributos no permite demostrar duplicación de individuos.

La partición 80/20 se ejecuta antes de aprender imputaciones, codificación o escalamiento y utiliza stratify=y para preservar la proporción de clases. El pipeline numérico imputa con mediana y estandariza; el pipeline categórico imputa con la categoría más frecuente y aplica OneHotEncoder(drop='first', handle_unknown='ignore'). El preprocesador se ajusta solo con entrenamiento, práctica coherente con la documentación oficial de ColumnTransformer/Pipeline para datos heterogéneos (scikit-learn Developers, 2026c).

Control	Resultado
X_train / X_test	712 / 179 observaciones
Predictores transformados	8
NaN después del preprocesamiento (train)	0
NaN después del preprocesamiento (test)	0
Proporción clase 1 en train	38,34%
Proporción clase 1 en test	38,55%

VIII. Análisis exploratorio inicial del conjunto de datos

La variable objetivo presenta 549 observaciones de clase 0 (61,62%) y 342 de clase 1 (38,38%), equivalente a una razón mayoritaria/minoritaria de 1,61. El desbalance es moderado; por ello accuracy se complementa con precision, recall, F1 y balanced accuracy.




Figura 5. Distribución de clases de survived.




Figura 6. Valores faltantes en los predictores seleccionados.

Variable	Categoría	N	Tasa clase 1
sex	female	314	0,7420

Variable	Categoría	N	Tasa clase 1
sex	male	577	0,1889
pclass	1	216	0,6296
pclass	2	184	0,4728
pclass	3	491	0,2424
embarked	C	168	0,5536
embarked	Q	77	0,3896
embarked	S	644	0,3370

Tabla 10. Patrones categóricos relevantes del EDA.

Las diferencias más marcadas aparecen en sex y pclass: la tasa empírica de clase 1 es 74,20% en mujeres frente a 18,89% en hombres, y disminuye desde 62,96% en primera clase a 24,24% en tercera. En embarked, Cherbourg presenta una tasa de 55,36%. Los dos valores faltantes de embarked corresponden a clase 1, pero su tamaño muestral es demasiado pequeño para interpretarlo como patrón estable.

En variables numéricas, fare muestra una separación descriptiva mayor que age: la tarifa media es 48,40 en la clase 1 y 22,12 en la clase 0, mientras las medianas de age son 28 años en ambas clases. Estos hallazgos justifican conservar variables socioeconómicas, demográficas y de viaje y aplicar imputación/transformación antes del MLP.




Figura 7. Tasa empírica de clase 1 en variables categóricas.




Figura 8. Distribuciones de age y fare condicionadas por la clase.

IX. Notebook F3_RedesNeuronales.ipynb y documentación del proceso

El notebook consolida la evidencia computacional de RA2 y RA3 en un flujo reproducible: control del entorno, regresión, ajuste paramétrico, clasificación, EDA, preprocesamiento, entrenamiento, evaluación y control de artefactos. La corrida archivada contiene 31 celdas, 15 celdas de código ejecutadas secuencialmente (1-15) y cero errores.

Componente	Versión
Python	3.12.4
NumPy	1.26.4
pandas	2.2.2
scikit-learn	1.4.2
Matplotlib	3.8.4

Tabla 11. Entorno registrado durante la ejecución.

La última celda verifica la existencia de las tablas y figuras obligatorias, calcula huellas SHA-256 y genera un manifiesto de artefactos. La trazabilidad entre criterios y archivos se conserva en `Semana3/docs/TRAZABILIDAD_RUBRICA.md`. El notebook no modifica manualmente sus métricas: las tablas se producen directamente desde las predicciones de la corrida.

Etapas	Evidencia principal
Regresión - datos/preparación	outputs 01-06
Regresión - implementación/tuning	outputs 07-11; figuras 03-04
Clasificación - datos/EDA	outputs 12-21b; figuras 05-08
Arquitecturas MLP	outputs 22-29; figuras 09, 12-13
Comparación	output 32; figuras 14-15
Control reproducible	outputs 00 y 33-35

Tabla 12. Trazabilidad resumida notebook-repositorio.

X. Red neuronal con una capa oculta

La arquitectura utiliza `hidden_layer_sizes=(100,)`, activación ReLU y optimizador Adam. Se mantienen `alpha=0,0001`, `learning_rate_init=0,001`, `max_iter=500`, `early_stopping=True`, `validation_fraction=0,15`, `n_iter_no_change=20`, `tol=0,0001` y `random_state=42`. Mantener constantes estos parámetros permite concentrar la comparación en la arquitectura oculta (Ruede Zúñiga, 2026; scikit-learn Developers, 2026a).

Accuracy	Precision	Recall	F1	Balanced acc.	Especificidad	TN	FP	FN	TP
0.7765	0.7544	0.6232	0.6825	0.7480	0.8727	96	14	26	43

Tabla 13. Resultados de MLP 1 capa oculta.




Figura 9. Matriz de confusión de MLP 1 capa oculta.

El modelo alcanza `accuracy=0.7765` y `F1=0.6825`. Identifica 43 verdaderos positivos y deja 26 falsos negativos. Su recall (0.6232) es inferior al de la arquitectura de dos capas. Se detuvo tras 72 iteraciones sin advertencias de entrenamiento; el gap F1 train-test fue 0.0437. Funciona como línea base neuronal de menor complejidad, con 1.001 parámetros entrenables.

XI. Red neuronal con dos capas ocultas

La arquitectura utiliza `hidden_layer_sizes=(100, 50)`, activación ReLU y optimizador Adam. Se mantienen `alpha=0,0001`, `learning_rate_init=0,001`, `max_iter=500`, `early_stopping=True`, `validation_fraction=0,15`, `n_iter_no_change=20`, `tol=0,0001` y `random_state=42`. Mantener constantes estos parámetros permite concentrar la comparación en la arquitectura oculta (Ruede Zúñiga, 2026; scikit-learn Developers, 2026a).

Accuracy	Precision	Recall	F1	Balanced acc.	Especificidad	TN	FP	FN	TP
0.7933	0.7353	0.7246	0.7299	0.7805	0.8364	92	18	19	50

Tabla 14. Resultados de MLP 2 capas ocultas.




Figura 10. Matriz de confusión de MLP 2 capas ocultas.

El modelo alcanza `accuracy=0.7933`, `recall=0.7246`, `F1=0.7299` y `balanced accuracy=0.7805`, los valores más altos de la comparación global para esas métricas. Registra 50 verdaderos positivos y 19 falsos negativos, la menor cantidad de FN entre las tres arquitecturas. Se detuvo tras 52 iteraciones sin advertencias; el gap F1 train-test fue 0.0424. La mejora respecto de una capa compensa el aumento a 6.001 parámetros bajo el criterio de desempeño equilibrado.

XII. Red neuronal con tres capas ocultas

La arquitectura utiliza `hidden_layer_sizes=(100, 50, 25)`, activación ReLU y optimizador Adam. Se mantienen `alpha=0,0001`, `learning_rate_init=0,001`, `max_iter=500`, `early_stopping=True`, `validation_fraction=0,15`, `n_iter_no_change=20`, `tol=0,0001` y `random_state=42`. Mantener constantes estos parámetros permite concentrar la comparación en la arquitectura oculta (Ruede Zúñiga, 2026; scikit-learn Developers, 2026a).

Accuracy	Precision	Recall	F1	Balanced acc.	Especificidad	TN	FP	FN	TP
0.7877	0.8163	0.5797	0.6780	0.7489	0.9182	101	9	29	40

Tabla 15. Resultados de MLP 3 capas ocultas.




Figura 11. Matriz de confusión de MLP 3 capas ocultas.

El modelo obtiene la mayor precisión (0.8163) y especificidad (0.9182), con solo 9 falsos positivos. Sin embargo, su recall cae a 0.5797 y genera 29 falsos negativos. El gap F1 train-test (0.0829) es el mayor y la arquitectura utiliza 7.251 parámetros. La mayor profundidad no produce una mejora global en esta corrida; su ventaja aparece específicamente cuando se prioriza evitar falsos positivos.

XIII. Desempeño de redes neuronales

Las tres arquitecturas se evalúan sobre las mismas 179 observaciones de prueba. La matriz de confusión permite distinguir tipos de error y las métricas resumen dimensiones diferentes del desempeño; por ello ninguna se interpreta de forma aislada (Universidad Andrés Bello, 2026).

Modelo	Acc.	Prec.	Recall	F1	Bal. acc.	FP	FN
MLP 1 capa oculta	0.7765	0.7544	0.6232	0.6825	0.7480	14	26
MLP 2 capas ocultas	0.7933	0.7353	0.7246	0.7299	0.7805	18	19
MLP 3 capas ocultas	0.7877	0.8163	0.5797	0.6780	0.7489	9	29

Tabla 16. Comparación cuantitativa de desempeño de las tres arquitecturas.




Figura 12. Comparación de métricas de las arquitecturas MLP.

El MLP de dos capas lidera accuracy, recall, F1 y balanced accuracy. El MLP de tres capas produce la mayor precisión y especificidad, pero a costa de una reducción del recall. Esta diferencia ilustra por qué la matriz de confusión y el costo relativo de FP/FN deben acompañar a accuracy.

XIV. Comparación de arquitecturas de redes neuronales

Modelo	Parámetros	Iter.	Acc.	F1	Gap F1	FP	FN
MLP 1 capa oculta	1001	72	0.7765	0.6825	0.0437	14	26
MLP 2 capas ocultas	6001	52	0.7933	0.7299	0.0424	18	19
MLP 3 capas ocultas	7251	50	0.7877	0.6780	0.0829	9	29

Tabla 17. Desempeño, complejidad y generalización.




Figura 13. Pérdida de entrenamiento por iteración.




Figura 14. Score de validación interna utilizado por early stopping.




Figura 15. Complejidad paramétrica de las arquitecturas.

La actividad no especifica una matriz de costos que determine si un falso positivo o un falso negativo es intrínsecamente más costoso. En ausencia de esa preferencia, la decisión se basa en desempeño equilibrado sobre test y estabilidad train-test. Bajo ese criterio, el MLP de dos capas es la arquitectura seleccionada: presenta el mayor F1 y balanced accuracy y la menor cantidad de falsos negativos, manteniendo una brecha de generalización similar a la red de una capa.

El MLP de tres capas sería defendible si el objetivo fuese maximizar precisión/especificidad y penalizar especialmente los falsos positivos. Sin embargo, esa prioridad no está establecida por el caso. Su mayor cantidad de parámetros y mayor gap F1 no se justifican por una mejora global del desempeño.

Decisión de clasificación

Seleccionar `MLPClassifier` con dos capas ocultas (100, 50) como arquitectura más pertinente para esta corrida. Conservar la red de una capa como referencia de menor complejidad y la de tres capas como alternativa de mayor precisión/especificidad.

XV. Conclusiones

La Sumativa 2 integra dos etapas del proyecto bajo un criterio común de reproducibilidad: separar entrenamiento y prueba antes de aprender transformaciones, ajustar hiperparámetros sin utilizar el test y fundamentar las decisiones a partir de resultados verificables.

En regresión, California Housing no requirió imputación y la selección del predictor simple se efectuó solo con entrenamiento. GridSearchCV mejoró sustancialmente el árbol: RMSE disminuyó 16.80% y R^2 aumentó 0.123182. Pese a esa mejora, el MLPRegressor mantuvo el menor RMSE (0.549301), el mayor R^2 (0.769742) y una brecha train-test menor que el árbol ajustado, por lo que se selecciona como modelo predictivo principal.

En clasificación, la exploración mostró un desbalance moderado y asociaciones descriptivas relevantes con sex, pclass y fare. La partición estratificada y el preprocesamiento aprendido únicamente con entrenamiento permitieron evaluar las tres redes bajo condiciones comparables. El MLP de dos capas obtuvo el mejor compromiso global entre accuracy, recall, F1 y balanced accuracy, con 19 falsos negativos; la red de tres capas incrementó precision y especificidad, pero redujo el recall y presentó la mayor brecha F1 train-test.

La evidencia confirma que aumentar la profundidad no garantiza mejor generalización. La selección final se apoya en la combinación de desempeño, tipos de error, complejidad y estabilidad, coherente con el principio docente de que un modelo debe justificarse por su pertinencia y comportamiento sobre datos no vistos, no por una única métrica (Ruede Zúñiga, 2026; Universidad Andrés Bello, 2026).

XVI. Uso de fuentes, citación y referencias

Las fuentes se integraron en el desarrollo para sustentar decisiones metodológicas, uso de herramientas y criterios de evaluación. La distribución incluye material docente, documentación técnica oficial y bibliografía académica complementaria, conforme a la rúbrica.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An Introduction to Statistical Learning: With Applications in Python*. Springer.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Ruete Zúñiga, D. (2026). *Redes neuronales [Apunte]*. Universidad Andrés Bello.

Universidad Andrés Bello. (2026). Fase 3: modelos de clasificación supervisada. Implementación, ajuste, evaluación y comparación [Presentación de apoyo, MCDI504].

scikit-learn Developers. (2026a). MLPClassifier. Scikit-learn documentation.

https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html

scikit-learn Developers. (2026b). GridSearchCV. Scikit-learn documentation.

https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

scikit-learn Developers. (2026c). Column Transformer with Mixed Types. Scikit-learn documentation.

https://scikit-learn.org/stable/auto_examples/compose/plot_column_transformer_mixed_types.html

XVII. Anexos

Anexo A. Evidencia de control y reproducibilidad

Control	Resultado
Celdas de código ejecutadas	15/15
Errores de ejecución	0
random_state	42
Artefactos obligatorios	Todos presentes
NaN posteriores al preprocesamiento	0 en train y 0 en test
Advertencias de entrenamiento MLP	0

Tabla A1. Controles de la corrida.

Anexo B. Variables transformadas para clasificación

Variable transformada
pclass
age
sibsp
parch
fare
sex_male
embarked_Q
embarked_S

Tabla B1. Ocho predictores utilizados por las redes.

Anexo C. Evidencia complementaria de generalización

Modelo	Acc train	Acc test	Gap acc	F1 train	F1 test	Gap F1
MLP 1 capa oculta	0.8062	0.7765	0.0296	0.7262	0.6825	0.0437
MLP 2 capas ocultas	0.8244	0.7933	0.0311	0.7723	0.7299	0.0424
MLP 3 capas ocultas	0.8385	0.7877	0.0508	0.7609	0.6780	0.0829

Tabla C1. Brechas train-test de las arquitecturas MLP.

Anexo D. Trazabilidad con la rúbrica

Criterio	Evidencia	Ubicación
C1	Descripción y preparación de regresión	Informe II; outputs 01-06; figuras 01-02
C2	Implementación de regresión	Informe III; output 07; output 10
C3	Ajuste de hiperparámetros	Informe IV; outputs 08-09; figura 03
C4	Métricas de regresión	Informe V; outputs 10-11; figura 04
C5	Comparación de regresión	Informe VI; output 10; tabla comparativa del informe

Criterio	Evidencia	Ubicación
C6	Datos y preparación de clasificación	Informe VII; outputs 12–14b y 19–21b
C7	EDA de clasificación	Informe VIII; outputs 15–18; figuras 05–08
C8	Notebook y documentación	Informe IX; notebook ejecutado; outputs 00 y 33–35
C9	MLP una capa	Informe X; outputs 22–24; matriz 29_1; figura 09_1
C10	MLP dos capas	Informe XI; outputs 22–24; matriz 29_2; figura 09_2
C11	MLP tres capas	Informe XII; outputs 22–24; matriz 29_3; figura 09_3
C12	Desempeño de redes	Informe XIII; outputs 23–29; figuras 09, 12–14
C13	Comparación de arquitecturas	Informe XIV; output 32; figuras 14–15
C14	Conclusiones	Informe XV
C15	Portada e índice	Informe I
C16	Formato institucional	DOCX/PDF en tamaño carta; Calibri 11; estructura jerárquica
C17	Ortografía y gramática	Revisión final del informe
C18	Fuentes, citación y referencias	Informe XVI; docs/FUENTES_BASE.md
C19	Anexos	Informe XVII; tablas y figuras derivadas de la corrida

Tabla D1. Matriz de trazabilidad de los 19 criterios.

Las tablas CSV, matrices de confusión, curvas y manifiestos completos se conservan en `Semana3/outputs/` y `Semana3/figures/`. El informe resume la evidencia necesaria sin reemplazar el notebook ejecutado.