

MCDI504

MACHINE LEARNING I

AVANCE DEL PROYECTO - FASE 4:

EVALUACIÓN Y VALIDACIÓN DEL MODELO

Integrantes: Luis Díaz Giral; Gonzalo Bouldres; Eduardo Contreras

Curso: MCDI504 - Machine Learning I

Docente: Dr. David Ruete Zúñiga

Fecha: Agosto 2026

Grupo: GRUPO6

APARTADOS

- I. Portada e índice
- II. Descripción de los modelos y del conjunto de datos para evaluación
- III. Preparación del proceso de evaluación
- IV. Notebook F4_Evaluacion.ipynb y documentación del proceso
- V. Evaluación de modelos supervisados
- VI. Matriz de confusión y métricas de clasificación
- VII. Validación cruzada de red neuronal con una capa oculta
- VIII. Interpretación comparativa de resultados
- IX. Justificación metodológica de la evaluación utilizada
- X. Conclusiones
- XI. Uso de fuentes, citación y referencias
- XII. Anexos

Repositorio del proyecto: <https://github.com/edocontreras/mcdi504-machine-learning-1> | Notebook: Semana4/Formativa/notebook/F4_Evaluacion.ipynb

II. Descripción de los modelos y del conjunto de datos para evaluación

La Evaluación Formativa 4 corresponde al avance de la Fase 4 del proyecto ABP. Su propósito es evaluar el desempeño de los modelos de clasificación considerados en el proyecto, documentar sus errores mediante matrices de confusión y aplicar validación cruzada a una red neuronal con una capa oculta. El informe, el notebook y el repositorio se tratan como evidencias de un mismo flujo reproducible (Ruete Zúñiga, 2026a, 2026b).

El caso utiliza el dataset Titanic archivado en Semana 3. Se analizaron 891 pasajeros; la variable objetivo es survived y la clase positiva es 1 = sobrevivió. La distribución general es 549 no sobrevivientes (61,6 %) y 342 sobrevivientes (38,4 %), por lo que accuracy se interpreta junto con métricas específicas de la clase positiva.

Elemento	Descripción aplicada
Dataset	Titanic; 891 observaciones y 15 columnas originales.
Variable objetivo	survived: 0 = no sobrevivió; 1 = sobrevivió.
Clase positiva	1 = sobrevivió.
Predictores	pclass, age, sibsp, parch, fare, sex, embarked.
Hold-Out	712 train y 179 test; 80/20 estratificado, random_state=42.
Propósito	Comparar desempeño puntual y analizar estabilidad del MLP de una capa.

2.1 Modelos considerados

Modelo	Configuración
KNN	n_neighbors=5; metric=minkowski; p=2; escalamiento numérico
Árbol de decisión	criterion=gini; max_depth=5; random_state=42
SVM	kernel=rbf; C=1; escalamiento numérico
Naive Bayes	GaussianNB
MLP 1 capa oculta	hidden_layer_sizes=(100,); parámetros MLP heredados de Semana 3
MLP 2 capas ocultas	hidden_layer_sizes=(100, 50); parámetros MLP heredados de Semana 3
MLP 3 capas ocultas	hidden_layer_sizes=(100, 50, 25); parámetros MLP heredados de Semana 3




Figura 1. Distribución de la variable objetivo survived.

III. Preparación del proceso de evaluación

La evaluación se construyó sobre una partición Hold-Out estratificada 80/20. La estratificación conserva prácticamente la misma prevalencia de la clase positiva en entrenamiento (38,34 %) y prueba (38,55 %). Imputación, One-Hot Encoding y escalamiento se integraron en Pipeline/ColumnTransformer, de modo que el aprendizaje de parámetros de preprocesamiento se realiza solo con datos de entrenamiento; en K-Fold, el pipeline se reajusta dentro de cada fold (scikit-learn Developers, 2026c).

Componente	Decisión	Fundamento
Partición	train_test_split(test_size=0.20, stratify=y, random_state=42)	Reserva test y mantiene proporción de clases.
Númericas	Imputación por mediana	Evita eliminar observaciones por age faltante.
Catógoricas	Moda + OneHotEncoder(drop="first")	Completa embarked y codifica categorías.
Escalamiento	StandardScaler en KNN, SVM y MLP	Evita dominancia por magnitudes de escala.
Clase positiva	survived=1	Define precision, recall y F1.




Figura 2. Valores faltantes relevantes antes del preprocesamiento.




Figura 3. Partición Hold-Out estratificada utilizada.

3.1 Métricas y criterios de interpretación

Métrica	Interpretación en el caso
Accuracy	Proporción global de predicciones correctas.
Precision	Confiabilidad de las predicciones de supervivencia.
Recall	Cobertura de sobrevivientes reales.
F1-score	Equilibrio armónico entre precision y recall.
ROC-AUC	Capacidad de ordenar ambas clases a través de umbrales.
Average Precision	Resumen de precision-recall para la clase positiva.

La matriz de confusión se interpreta con filas = clase real y columnas = clase predicha. Los falsos negativos (FN) representan sobrevivientes reales clasificados como no sobrevivientes; los falsos positivos (FP) representan el error inverso. Esta lectura conjunta evita seleccionar un modelo únicamente por accuracy (Ruete Zúñiga, 2026a).

IV. Notebook F4_Evaluacion.ipynb y documentación del proceso

El notebook ejecutado constituye la evidencia técnica central. Está organizado en seis bloques narrativos y siete celdas de código ejecutadas secuencialmente, sin errores almacenados. La implementación utiliza scikit-learn como biblioteca principal de aprendizaje automático (Pedregosa et al., 2011). La última celda verificó completitud de artefactos, cobertura OOF, separación respecto del test y consistencia de las matrices.

Etapa	Evidencia
Entorno y rutas	Versiones, localización de raíz y limpieza de outputs/figures de la Formativa.
Dataset y modelos	Perfil, clases, configuraciones y continuidad de los tres MLP con Semana 3.
Preparación	Split estratificado, balance y criterios de métricas.
Hold-Out	7 modelos, predicciones, matrices, métricas, ranking y advertencias.
K-Fold MLP 1 capa	5 folds estratificados, OOF, matrices, estabilidad y costo.
Cierre	Trazabilidad, control de artefactos, manifiesto y metadata.

Los controles finales de la corrida fueron: “Control final de consistencia: OK”, “Validación cruzada MLP 1 capa: OK” y “Artefactos requeridos: OK”. No se registraron advertencias de convergencia ni errores durante la ejecución archivada.

Repositorio del proyecto: <https://github.com/edocontreras/mcdi504-machine-learning-1>

V. Evaluación de modelos supervisados

Los siete modelos se entrenaron con la misma partición Hold-Out de 179 observaciones y con preprocesamiento encapsulado en pipelines. La tabla resume resultados sobre la clase positiva $\text{survived}=1$. El ranking se presenta por F1-score para equilibrar precisión y recall; es una comparación preliminar, porque únicamente el MLP de una capa se somete en esta actividad a validación cruzada.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	FP	FN
KNN	0.8156	0.8103	0.6812	0.7402	0.8353	11	22
Árbol de decisión	0.7654	0.7547	0.5797	0.6557	0.7971	13	29
SVM	0.8324	0.8305	0.7101	0.7656	0.8337	10	20
Naïve Bayes	0.7821	0.7273	0.6957	0.7111	0.8080	18	21
MLP 1 capa oculta	0.7765	0.7544	0.6232	0.6825	0.8360	14	26
MLP 2 capas ocultas	0.7933	0.7353	0.7246	0.7299	0.8522	18	19
MLP 3 capas ocultas	0.7877	0.8163	0.5797	0.6780	0.8370	9	29

SVM obtuvo la mayor accuracy (0,8324) y el mayor F1-score (0,7656), con 10 FP y 20 FN. El MLP de dos capas obtuvo el mayor recall (0,7246) y el mayor ROC-AUC (0,8522). Por tanto, la alternativa con mayor acierto global no coincide necesariamente con la de mayor sensibilidad a la clase positiva.




Figura 4. Accuracy Hold-Out de los siete modelos.




Figura 5. Comparación de accuracy, precision, recall y F1-score.

VI. Matriz de confusión y métricas de clasificación

Las matrices siguientes mantienen la convención [TN, FP; FN, TP]. La clase positiva es sobrevivió (1). Las cifras se recalculan desde las predicciones archivadas y coinciden exactamente con `09\_métricas\_holdout\_modelos.csv`.

6.1 KNN

Accuracy	Precision	Recall	F1	TN	FP	FN	TP
0.8156	0.8103	0.6812	0.7402	99	11	22	47




Figura 6. Matriz de confusión - KNN.

La matriz permite identificar explícitamente el balance de errores de KNN y complementar la lectura de las métricas agregadas.

6.2 Árbol de decisión

Accuracy	Precision	Recall	F1	TN	FP	FN	TP
0.7654	0.7547	0.5797	0.6557	97	13	29	40




Figura 7. Matriz de confusión - Árbol de decisión.

La matriz permite identificar explícitamente el balance de errores de Árbol de decisión y complementar la lectura de las métricas agregadas.

6.3 SVM

Accuracy	Precision	Recall	F1	TN	FP	FN	TP
0.8324	0.8305	0.7101	0.7656	100	10	20	49




Figura 8. Matriz de confusión - SVM.

SVM combina la mayor accuracy y F1 del Hold-Out con solo 10 falsos positivos y 20 falsos negativos.

6.4 Naive Bayes

Accuracy	Precision	Recall	F1	TN	FP	FN	TP
0.7821	0.7273	0.6957	0.7111	92	18	21	48




Figura 9. Matriz de confusión - Naive Bayes.

La matriz permite identificar explícitamente el balance de errores de Naive Bayes y complementar la lectura de las métricas agregadas.

6.5 MLP 1 capa oculta

Accuracy	Precision	Recall	F1	TN	FP	FN	TP
0.7765	0.7544	0.6232	0.6825	96	14	26	43




Figura 10. Matriz de confusión - MLP 1 capa oculta.

El MLP de una capa presenta 26 falsos negativos; esta limitación motiva revisar su estabilidad bajo K-Fold.

6.6 MLP 2 capas ocultas

Accuracy	Precision	Recall	F1	TN	FP	FN	TP
0.7933	0.7353	0.7246	0.7299	92	18	19	50




Figura 11. Matriz de confusión - MLP 2 capas ocultas.

El MLP de dos capas reduce los falsos negativos a 19 y alcanza el mayor recall del conjunto de candidatos.

6.7 MLP 3 capas ocultas

Accuracy	Precision	Recall	F1	TN	FP	FN	TP
0.7877	0.8163	0.5797	0.6780	101	9	29	40




Figura 12. Matriz de confusión - MLP 3 capas ocultas.

La matriz permite identificar explícitamente el balance de errores de MLP 3 capas ocultas y complementar la lectura de las métricas agregadas.

VII. Validación cruzada de red neuronal con una capa oculta

La rúbrica exige validar una red neuronal con una capa oculta. Se utilizó `MLPClassifier(hidden_layer_sizes=(100,))` con la configuración heredada de Semana 3 (scikit-learn Developers, 2026d) y `StratifiedKFold` con `k=5`, `shuffle=True` y `random_state=42` exclusivamente sobre las 712 observaciones de entrenamiento. Cada fold reajusta imputación,

codificación, escalamiento y MLP; así, el subconjunto de validación no participa en el aprendizaje de parámetros de preprocesamiento. StratifiedKFold preserva aproximadamente la proporción de clases en cada partición (scikit-learn Developers, 2026b).

Fold	Acc.	Prec.	Recall	F1	ROC-AUC	TN	FP	FN	TP
1	0.8042	0.7647	0.7091	0.7358	0.8658	76	12	16	39
2	0.7972	0.7955	0.6364	0.7071	0.8292	79	9	20	35
3	0.8310	0.8780	0.6545	0.7500	0.8730	82	5	19	36
4	0.7887	0.7222	0.7222	0.7222	0.8480	73	15	15	39
5	0.8169	0.8500	0.6296	0.7234	0.8693	82	6	20	34

Métrica	Media	SD muestral	Mín.	Máx.
Accuracy	0.8076	0.0167	0.7887	0.8310
Precision	0.8021	0.0630	0.7222	0.8780
Recall	0.6704	0.0426	0.6296	0.7222
F1_score	0.7277	0.0161	0.7071	0.7500
ROC_AUC	0.8571	0.0183	0.8292	0.8730




Figura 13. Accuracy por fold del MLP de una capa.




Figura 14. Estabilidad de métricas por fold.




Figura 15. Matriz OOF agregada del MLP de una capa.

La accuracy media fue 0,8076 con $SD=0,0167$ y el F1 medio 0,7277 con $SD=0,0161$, lo que evidencia baja variabilidad en esas métricas. Precision ($SD=0,0630$), recall ($SD=0,0426$) y especificidad ($SD=0,0471$) presentan mayor sensibilidad a la partición. La matriz OOF agregada $[[392, 47], [90, 183]]$ produce recall OOF de 0,6703; los 90 falsos negativos son el principal límite para la detección de sobrevivientes.

VIII. Interpretación comparativa de resultados

La comparación no debe reducirse a una sola métrica. En Hold-Out, SVM lidera accuracy y F1; el MLP de dos capas lidera recall y ROC-AUC; el MLP de una capa entrega la evidencia de estabilidad requerida por la actividad. Estas conclusiones son complementarias y no implican que los siete modelos hayan recibido una validación cruzada equivalente.

Modelo	Fortaleza principal	Limitación principal
SVM	Mayor accuracy (0,8324) y F1 (0,7656); 10 FP.	No fue sometido a K-Fold en esta Formativa.
KNN	Segundo F1 (0,7402) y buen desempeño global.	Recall 0,6812; sensible a vecindad/escala.
MLP 2 capas	Mayor recall (0,7246) y ROC-AUC (0,8522).	Mayor complejidad que MLP 1 capa; sin CV comparativa aquí.
MLP 1 capa	CV exigida: accuracy $0,8076 \pm 0,0167$; F1 $0,7277 \pm 0,0161$.	Recall moderado y 90 FN OOF.
Naive Bayes	Recall 0,6957 con bajo costo computacional.	Mayor FPR que SVM/KNN.
MLP 3 capas	Mayor especificidad 0,9182 y solo 9 FP.	Recall 0,5797 y 29 FN.
Árbol	Reglas interpretables y especificidad 0,8818.	Menor F1 del grupo (0,6557).




Figura 16. Curva ROC del MLP de una capa en Hold-Out.




Figura 17. Curva precision-recall del MLP de una capa en Hold-Out.




Figura 18. MLP una capa: Hold-Out frente a media de validación cruzada.

En todas las métricas comparadas, el Hold-Out del MLP de una capa fue inferior a la media CV; por ejemplo, accuracy 0,7765 frente a 0,8076 y F1 0,6825 frente a 0,7277. Esto sugiere que esa partición puntual fue más exigente que el promedio de los cinco folds, sin invalidar la estimación de estabilidad. Para una selección final entre familias, la comparación debería repetirse con un protocolo de validación equivalente para cada candidato.

IX. Justificación metodológica de la evaluación utilizada

9.1 Pertinencia de las métricas

Accuracy resume aciertos globales, pero la prevalencia 61,6/38,4 hace necesario complementarla con precision, recall y F1 para la clase positiva. ROC-AUC y Average Precision aportan una lectura basada en scores y umbrales, útil para distinguir capacidad discriminativa de la decisión binaria específica (Ruete Zúñiga, 2026a; scikit-learn Developers, 2026a).

9.2 K-Fold frente a Hold-Out y Leave-One-Out

Técnica	N.º ajustes MLP1	Costo	Uso en el caso
Hold-Out	1	Bajo	Evaluación puntual sobre conjunto de prueba
K-Fold estratificado k=5	5	Medio	Estimación de estabilidad sobre entrenamiento
Leave-One-Out	712	Alto	Referencia teórica de costo; no ejecutada

Con 712 observaciones de entrenamiento, Hold-Out requiere un solo ajuste y no estima variabilidad entre particiones; Leave-One-Out implicaría 712 ajustes del MLP y un costo muy superior. K-Fold estratificado k=5 requiere cinco ajustes y proporcionó una estimación directa de dispersión, por lo que constituye un compromiso razonable entre costo y estabilidad (Ruete Zúñiga, 2026b; James et al., 2023).

El tiempo total observado de los cinco ajustes fue 0,895 s en el equipo de ejecución. Este valor se registra como evidencia reproducible de esa corrida, pero no se interpreta como constante portable entre computadores.

9.3 Coherencia y prevención de filtración

La validación se ejecuta exclusivamente sobre train y genera predicciones out-of-fold para las 712 observaciones, una vez por observación. Los controles confirman cobertura completa, índices OOF únicos, disjunción respecto del test y suma de la matriz agregada igual al tamaño de train. Además, el pipeline completo se reajusta por fold, evitando que la imputación, codificación o estandarización aprendan del fold de validación.

X. Conclusiones

La Formativa 4 permitió evaluar siete clasificadores sobre Titanic mediante un protocolo Hold-Out reproducible y aplicar la validación cruzada exigida al MLP de una capa oculta. SVM presentó el mejor desempeño puntual por accuracy (0,8324) y F1 (0,7656), mientras que el MLP de dos capas obtuvo el mayor recall (0,7246) y ROC-AUC (0,8522).

La validación del MLP de una capa obtuvo accuracy media $0,8076 \pm 0,0167$ y F1 $0,7277 \pm 0,0161$. Estas dos métricas son relativamente estables, pero recall mostró una variabilidad mayor (0,6296-0,7222) y la matriz OOF acumuló 90 falsos negativos. En consecuencia, la estabilidad no debe describirse de forma uniforme: el desempeño global es consistente, pero la detección de la clase positiva continúa siendo el principal punto crítico.

K-Fold estratificado $k=5$ resulta pertinente para este tamaño de datos porque mejora la evidencia respecto de una sola partición sin incurrir en los 712 ajustes requeridos por Leave-One-Out. El uso de pipelines dentro de cada fold mantiene coherencia metodológica y evita filtración de información.

Como decisión preliminar, SVM es el candidato más competitivo bajo el Hold-Out actual; no obstante, la selección final debería comparar los principales candidatos bajo un protocolo de validación equivalente y, si el contexto asigna costos distintos a FP y FN, incorporar explícitamente esa función de costos o ajustar el umbral sin utilizar el test para optimización.

XI. Uso de fuentes, citación y referencias

Las decisiones conceptuales y metodológicas se sustentan en material docente, documentación técnica oficial y bibliografía académica. Las citas incluidas en las secciones previas corresponden a las referencias siguientes.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An introduction to statistical learning: With applications in Python. Springer.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Ruete Zúñiga, D. (2026a). Métricas de evaluación: accuracy, F1-score, curva ROC-AUC, curvas precisión-recall, matriz de confusión [Material docente]. Universidad Andrés Bello.

Ruete Zúñiga, D. (2026b). Técnicas de evaluación: validación cruzada (K-Fold Cross-Validation, Leave-One-Out, Hold-Out) [Material docente]. Universidad Andrés Bello.

scikit-learn Developers. (2026a). Metrics and scoring: Quantifying the quality of predictions. scikit-learn 1.4 documentation. https://scikit-learn.org/1.4/modules/model_evaluation.html

scikit-learn Developers. (2026b). StratifiedKFold. scikit-learn 1.4 documentation. https://scikit-learn.org/1.4/modules/generated/sklearn.model_selection.StratifiedKFold.html

scikit-learn Developers. (2026c). Pipeline. scikit-learn 1.4 documentation. <https://scikit-learn.org/1.4/modules/generated/sklearn.pipeline.Pipeline.html>

scikit-learn Developers. (2026d). MLPClassifier. scikit-learn 1.4 documentation. https://scikit-learn.org/1.4/modules/generated/sklearn.neural_network.MLPClassifier.html

XII. Anexos

Anexo A. Resultados Hold-Out completos

Modelo	TN	FP	FN	TP	Acc.	Prec.	Recall	F1
KNN	99	11	22	47	0.8156	0.8103	0.6812	0.7402
Árbol de decisión	97	13	29	40	0.7654	0.7547	0.5797	0.6557
SVM	100	10	20	49	0.8324	0.8305	0.7101	0.7656
Naive Bayes	92	18	21	48	0.7821	0.7273	0.6957	0.7111
MLP 1 capa oculta	96	14	26	43	0.7765	0.7544	0.6232	0.6825
MLP 2 capas ocultas	92	18	19	50	0.7933	0.7353	0.7246	0.7299
MLP 3 capas ocultas	101	9	29	40	0.7877	0.8163	0.5797	0.6780

Anexo B. Evidencia de validación y costo

Control	Valor
OOB_cubre_todo_train	True
Indice_OOB_unicos	True
OOB_disjunto_test	True
Matriz_agregada_suma_train	True

Métrica MLP1	Hold-Out	Media CV	Diferencia H-CV
Accuracy	0.7765	0.8076	-0.0311
Precision	0.7544	0.8021	-0.0477
Recall	0.6232	0.6704	-0.0472
F1_score	0.6825	0.7277	-0.0452
ROC_AUC	0.8360	0.8571	-0.0211
Average_Precision	0.7557	0.8237	-0.0681

Anexo C. Trazabilidad de criterios

Criterio	Evidencia notebook	Artefactos
C1 Descripción de modelos y dataset	Secciones 1-2	01_perfil_dataset.csv; 03_distribucion_clases.csv; 04_modelos_configuracion.csv
C2 Preparación del proceso de evaluación	Sección 2	06_dimensiones_split.csv; 07_balance_train_test.csv; 08_criterios_metricas.csv
C3 Evaluación de modelos supervisados	Sección 3	09_metricas_holdout_modelos.csv; 14_ranking_preliminar.csv
C4 Matriz de confusión y métricas	Sección 3	09_metricas_holdout_modelos.csv; 12_matrices_confusion_holdout.csv; figuras 06-12
C5 Validación cruzada MLP una capa	Sección 4	16_cv_mlp1_metricas_por_fold.csv; 22_cv_mlp1_resumen_estabilidad.csv; 21_cv_mlp1_matriz_agregada.csv
C6 Interpretación comparativa	Sección 5	25_comparacion_mlp1_holdout_cv.csv; 27_resumen_para_decision.csv
C7 Justificación metodológica	Secciones 4-5	24_costo_validacion.csv; 22_cv_mlp1_resumen_estabilidad.csv
C8 Notebook y documentación	Flujo completo y control final	28_trazabilidad_rubrica.csv; 29_control_artefactos_requeridos.csv
C10-C14 Criterios formales	No sustituyen al informe PDF	Se completan en el informe final con resultados de esta ejecución

Los criterios formales - portada e índice, formato institucional, ortografía, fuentes y anexos - se materializan en este informe PDF y se respaldan adicionalmente en `Semana4/Formativa/docs/TRAZABILIDAD\_RUBRICA.md`.