

MCDI504

MACHINE LEARNING I

INFORME FINAL DEL PROYECTO - FASE 4: EVALUACIÓN Y VALIDACIÓN DEL MODELO

Nombre integrante/s: Luis Díaz Giral, Gonzalo Bouldres y Eduardo Contreras

Curso: MCDI504 - Machine Learning I

Evaluación: Semana 04. Sumativa 3: Informe final del proyecto Fase 4

Docente: Dr. David Ruete Zúñiga

Fecha: 1 de septiembre de 2026

Grupo: 6

Repositorio: <https://github.com/edocontreras/mcdi504-machine-learning-1>

APARTADOS

I. Portada e índice	1
II. Evaluación del desempeño del modelo	3
III. Reporte tabulado e interpretación de métricas del modelo	5
IV. Matriz de confusión y métricas de clasificación	6
V. Interpretación del desempeño del modelo	8
VI. Interpretación para toma de decisiones	10
VII. Notebook y trazabilidad del proceso de evaluación del modelo	11
VIII. Conclusiones técnicas del desempeño del modelo	12
IX. Reporte tabulado e interpretación de estabilidad de métricas	13
X. Justificación de técnica de validación	16
XI. Coherencia metodológica de validación	17
XII. Notebook y trazabilidad del proceso de validación	18
XIII. Conclusiones técnicas del proceso de validación	19
XIV. Uso de fuentes, citación y referencias	20
XV. Anexos	21

El informe, el notebook y el repositorio se presentan como componentes de un mismo flujo trazable. Las cifras reportadas en las secciones II-XIII proceden de la corrida archivada en [Semana4/outputs/](#).

II. Evaluación del desempeño del modelo

La Fase 4 consolida la evaluación y validación del clasificador seleccionado en Semana 3. El problema analítico consiste en predecir la variable binaria *survived* del dataset Titanic a partir de atributos demográficos, socioeconómicos y de viaje. La clase positiva se define como *survived* = 1 (sobrevivió). El modelo evaluado es un *MLPClassifier* con dos capas ocultas de 100 y 50 neuronas, seleccionado previamente por su desempeño equilibrado en la comparación arquitectónica de Semana 3. En esta fase no se reabre la selección del modelo; se caracteriza su desempeño y se estima su estabilidad.

La evaluación utiliza la partición histórica 80/20 de Semana 3: 712 observaciones de entrenamiento y 179 de prueba. Dado que ese Hold-Out ya participó en la comparación de arquitecturas, se interpreta como evidencia histórica de desempeño y continuidad, no como una muestra completamente independiente posterior a la selección. La evidencia nueva de estabilidad se obtiene mediante validación cruzada estratificada de cinco folds aplicada exclusivamente al subconjunto de entrenamiento. Esta distinción evita atribuir al Hold-Out una independencia que el flujo histórico del proyecto no posee.

El pipeline integra imputación, codificación One-Hot, estandarización y MLP. Durante la validación cruzada, el pipeline completo se reajusta dentro de cada fold, de modo que los parámetros aprendidos por el preprocesamiento no utilizan el fold de validación. Este diseño responde a la regla de evitar filtración de información durante la evaluación (Ruete Zúñiga, 2026b; scikit-learn Developers, s. f.-a).

Elemento	Configuración final
Problema analítico	Clasificación binaria de supervivencia en Titanic.
Dataset	891 observaciones; 549 clase 0 y 342 clase 1.
Variable objetivo	<i>survived</i> : 0 = no sobrevivió; 1 = sobrevivió.
Clase positiva	Sobrevivió (1).
Predictores	<i>pclass</i> , <i>age</i> , <i>sibsp</i> , <i>parch</i> , <i>fare</i> , <i>sex</i> , <i>embarked</i> .
Modelo	<i>MLPClassifier</i> con <i>hidden_layer_sizes</i> =(100, 50).
Partición	712 train / 179 test, estratificada, <i>random_state</i> =42.
Validación	<i>StratifiedKFold</i> , <i>k</i> =5, solo sobre train.
Umbral	0,50; no optimizado con test.




Figura 1. Distribución de la variable objetivo survived en el dataset Titanic.

La clase 0 concentra 549 observaciones (61,62%) y la clase 1, 342 (38,38%). La diferencia no constituye un desbalance extremo, pero justifica complementar accuracy con precision, recall, F1-score y balanced accuracy. El material docente enfatiza que las métricas responden a preguntas distintas y deben leerse según el tipo de error relevante (Ruete Zúñiga, 2026a).

III. Reporte tabulado e interpretación de métricas del modelo

Las cuatro métricas obligatorias se calculan sobre las 179 observaciones del Hold-Out histórico. Accuracy resume el porcentaje global de clasificaciones correctas; precision cuantifica la proporción de predicciones positivas que corresponden realmente a la clase 1; recall mide la fracción de positivos reales detectados; y F1-score integra precision y recall mediante su media armónica (Ruete Zúñiga, 2026a).

Métrica	Valor	Interpretación en el caso
Accuracy	0,7933	79,33% de las observaciones del test fueron clasificadas correctamente.
Precision	0,7353	73,53% de las predicciones sobrevivió correspondieron a sobrevivientes reales.
Recall	0,7246	72,46% de los sobrevivientes reales fueron detectados.
F1-score	0,7299	Resume el equilibrio observado entre precision y recall para la clase positiva.
Balanced accuracy	0,7805	Promedia sensibilidad y especificidad, útil ante diferencias de prevalencia.
ROC-AUC	0,8522	Capacidad discriminativa global al variar el umbral.
Average precision	0,7891	Síntesis de la relación precision-recall a través de umbrales.

El desempeño no debe resumirse únicamente por accuracy. El recall inferior a la especificidad muestra que el modelo es menos eficaz para recuperar positivos reales que para reconocer negativos reales. A la vez, ROC-AUC = 0,8522 indica una capacidad de discriminación claramente superior a la referencia aleatoria de 0,5. La lectura conjunta de métricas es coherente con la recomendación de evaluar el modelo según errores, discriminación y objetivo analítico, no por un único indicador (James et al., 2023; Ruete Zúñiga, 2026a).

IV. Matriz de confusión y métricas de clasificación

La matriz de confusión se presenta con filas como clase real y columnas como clase predicha. Para la clase positiva sobrevivió (1), los falsos negativos corresponden a pasajeros que sobrevivieron realmente, pero fueron clasificados como no sobrevivientes; los falsos positivos corresponden a pasajeros de clase 0 predichos como clase 1.

Componente	N
Verdaderos negativos (TN)	92
Falsos positivos (FP)	18
Falsos negativos (FN)	19
Verdaderos positivos (TP)	50
Total test	179




Figura 2. Matriz de confusión del MLP de dos capas sobre el Hold-Out histórico.

La matriz contiene 92 TN, 18 FP, 19 FN y 50 TP. La tasa de falsos negativos es 27,54%, mientras que la tasa de falsos positivos es 16,36%. Los cuatro componentes reproducen exactamente $\text{accuracy} = 0,7933$, $\text{precision} = 0,7353$, $\text{recall} = 0,7246$ y $\text{F1} = 0,7299$. La correspondencia se verificó además desde las predicciones individuales almacenadas en `24\_predicciones\_holdout.csv`.

Clase/resumen	Precision	Recall	F1	Support
No_sobrevivio_0	0,8288	0,8364	0,8326	110
Sobrevivio_1	0,7353	0,7246	0,7299	69

Clase/resumen	Precision	Recall	F1	Support
macro avg	0,7821	0,7805	0,7813	179
weighted avg	0,7928	0,7933	0,7930	179

El reporte por clase se mantiene separado de la accuracy global. Esta decisión evita asignar un support sin significado a una fila de accuracy y conserva una representación estadística explícita de las dos clases y de los promedios macro y ponderado.

V. Interpretación del desempeño del modelo

El MLP logra accuracy de 0,7933 y F1 de 0,7299 en el Hold-Out histórico. Su principal fortaleza es mantener un desempeño razonablemente equilibrado sin advertencias de convergencia en la corrida archivada. La red se detiene anticipadamente a las 52 iteraciones, antes de `max_iter=500`, con 6.001 parámetros entrenables. La evaluación complementaria permite caracterizar no solo aciertos globales, sino también la capacidad discriminativa y el perfil de errores.

La principal limitación observada se concentra en la recuperación de la clase positiva. El recall de 0,7246 implica que 27,54% de los positivos reales del Hold-Out no fueron detectados. En contraste, la especificidad de 0,8364 indica mayor capacidad para reconocer la clase 0. Esta asimetría no autoriza a calificar un tipo de error como universalmente más grave, porque el caso pedagógico no define una matriz de costos; sí obliga a explicitar qué error se priorizaría antes de trasladar el procedimiento a un contexto aplicado.




Figura 3. Curva ROC del Hold-Out histórico.




Figura 4. Curva Precision-Recall del Hold-Out histórico.

ROC-AUC = 0,8522 resume la discriminación global a través de umbrales. Average precision = 0,7891 se sitúa ampliamente por encima de la prevalencia positiva del test (38,55%), lo que aporta evidencia adicional sobre la capacidad del modelo para ordenar casos positivos. Las curvas se interpretan como complementos de la matriz de confusión y no como sustitutos de la evaluación al umbral 0,50 (Ruete Zúñiga, 2026a).

Una segunda limitación metodológica es histórica: el Hold-Out ya fue utilizado durante la comparación arquitectónica de Semana 3. Por ello no se presenta como una estimación completamente independiente posterior a la selección. La Fase 4 compensa esta limitación aportando validación cruzada sobre entrenamiento, pero una evaluación futura con una muestra externa o un test final no utilizado durante selección ofrecería una estimación más estricta de generalización.

VI. Interpretación para toma de decisiones

El caso Titanic se utiliza con fines formativos; por tanto, la utilidad del modelo consiste en demostrar cómo una clasificación binaria puede apoyar decisiones basadas en datos cuando existe una clase objetivo y distintos costos potenciales de error. No se interpreta el modelo como herramienta histórica u operacional para decisiones reales sobre el Titanic. La lógica transferible es la selección de la métrica y del umbral de acuerdo con el objetivo aplicado.

Objetivo de decisión	Indicador	Implicancia
Priorizar detección de positivos	Recall	Reducir FN; el modelo actual detecta 72,46% de positivos reales en test.
Priorizar confiabilidad de alertas positivas	Precision	Reducir FP; 73,53% de las predicciones positivas son correctas.
Equilibrar precision y recall	F1-score	F1 = 0,7299 al umbral 0,50.
Evaluar discriminación global	ROC-AUC	ROC-AUC = 0,8522, independiente de un único umbral.
Mantener continuidad del proyecto	Umbral 0,50	No se optimiza con test; coincide con predict de scikit-learn.

El umbral 0,50 se conserva por continuidad y porque no existe una función de costos definida. El material docente señala que disminuir el umbral suele elevar recall a costa de precision, mientras aumentarlo produce el efecto contrario; por ello cualquier ajuste futuro debe formularse antes de observar el test y justificarse mediante un costo explícito o un criterio de validación (Ruede Zúñiga, 2026a).




Figura 5. Comparación entre desempeño Hold-Out y promedio de validación cruzada.

La comparación muestra que el desempeño depende de la muestra de evaluación. El promedio CV supera al Hold-Out en accuracy, precision y F1, mientras el recall del Hold-Out es mayor. Estas diferencias no representan modelos distintos: son realizaciones del mismo pipeline bajo particiones diferentes y deben interpretarse como evidencia de variabilidad, no como una competencia entre protocolos.

VII. Notebook y trazabilidad del proceso de evaluación del modelo

El notebook `Semana4/notebook/F4\_Evaluacion.ipynb` constituye la evidencia ejecutable del proceso. La corrida archivada contiene nueve celdas de código ejecutadas secuencialmente, sin errores almacenados. El flujo localiza la raíz del repositorio, verifica la continuidad con Semana 3, audita el dataset, reproduce el split, construye el pipeline, ejecuta K-Fold, evalúa el Hold-Out y finaliza con controles de consistencia y manifiesto SHA-256.

Etapa	Artefacto	Función
Entorno	00_versiones_entorno.csv	Versiones Python, NumPy, pandas, scikit-learn y Matplotlib.
Continuidad	02_verificacion_configuracion_semana3.csv	Contraste de la configuración MLP con Semana 3.
Datos	05_perfil_dataset.csv; 10_indices_split.csv	Perfil y partición reproducible.
Evaluación	22_metricas_holdout.csv; 23_matriz_confusion_holdout.csv	Métricas y matriz sobre test.
Errores	25_errores_holdout.csv	Casos FP/FN individualizados.
Validación	14-21 outputs	Folds, estabilidad, OOF, balance, advertencias y costo.
Integridad	39_manifiesto_artefactos.csv; 40_control_artefactos_requeridos.csv	SHA-256 y verificación 50/50.

Pipeline: imputación / One-Hot / StandardScaler / MLP

Validación: StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

Umbral: 0.50

Control final: consistencia OK / continuidad OK / artefactos OK

La utilización de `Pipeline` asegura que las transformaciones aprendidas se ajusten con el subconjunto de entrenamiento de cada fold, reduciendo riesgo de data leakage (scikit-learn Developers, s. f.-a). La implementación del MLP se apoya en `MLPClassifier` de scikit-learn (scikit-learn Developers, s. f.-c; Pedregosa et al., 2011).

Repositorio del proyecto: <https://github.com/edocontreras/mcdi504-machine-learning-1>. El enlace corresponde a la versión pública del repositorio utilizada para la entrega y permite verificar la trazabilidad entre notebook, resultados, figuras e informe.

VIII. Conclusiones técnicas del desempeño del modelo

La evaluación confirma que el MLP de dos capas mantiene un desempeño útil para el propósito pedagógico del caso: accuracy = 0,7933, F1 = 0,7299, ROC-AUC = 0,8522 y average precision = 0,7891. La matriz de confusión registra 92 TN, 18 FP, 19 FN y 50 TP. En consecuencia, el modelo no presenta un patrón de error simétrico: la tasa de falsos negativos (27,54%) es mayor que la tasa de falsos positivos (16,36%).

La interpretación técnica debe conservar dos condiciones: primero, el Hold-Out es histórico y ya intervino en la comparación de arquitecturas; segundo, el umbral 0,50 no fue optimizado con test. Estas condiciones fortalecen la trazabilidad porque delimitan qué puede inferirse de los resultados y qué requeriría nueva evidencia.

Como mejoras futuras se proponen: disponer de una muestra final independiente o externa, aplicar validación anidada si se reabre el ajuste de hiperparámetros, definir una función de costos antes de modificar el umbral y considerar calibración probabilística cuando la decisión dependa de probabilidades bien calibradas. Estas mejoras no son necesarias para demostrar el RA4, pero aumentarían la rigurosidad de una futura aplicación predictiva.

IX. Reporte tabulado e interpretación de estabilidad de métricas

La estabilidad se estima mediante cinco folds estratificados sobre las 712 observaciones de entrenamiento. Cada observación recibe una predicción out-of-fold exactamente una vez. La estratificación mantiene proporciones de clase comparables entre folds y reduce variaciones atribuibles únicamente a cambios severos en la prevalencia (scikit-learn Developers, s. f.-b).

Fold	Accuracy	Precision	Recall	F1	ROC-AUC
1	0,8322	0,8163	0,7273	0,7692	0,8561
2	0,8182	0,8537	0,6364	0,7292	0,8339
3	0,8451	0,8837	0,6909	0,7755	0,8868
4	0,8239	0,7736	0,7593	0,7664	0,8612
5	0,8099	0,8462	0,6111	0,7097	0,8733




Figura 6. Accuracy por fold del MLP con validación cruzada estratificada.




Figura 7. Variación de accuracy, precision, recall y F1-score entre folds.

Métrica	Promedio	SD muestral	Mínimo	Máximo	Rango
Accuracy	0,8258	0,0135	0,8099	0,8451	0,0352
Precision	0,8347	0,0417	0,7736	0,8837	0,1101
Recall	0,6850	0,0616	0,6111	0,7593	0,1481
F1-score	0,7500	0,0289	0,7097	0,7755	0,0658
ROC-AUC	0,8623	0,0198	0,8339	0,8868	0,0529
Average precision	0,8393	0,0263	0,7986	0,8698	0,0712

Accuracy presenta baja variabilidad: promedio 0,8258 y desviación estándar muestral 0,0135. Recall es la métrica obligatoria con mayor sensibilidad a la composición de los folds: promedio 0,6850, SD 0,0616 y rango 0,1481. Por ello no se afirma que todas las métricas tengan la misma estabilidad; la evidencia respalda estabilidad global razonable con mayor variabilidad específica en recall.




Figura 8. Matriz de confusión agregada de las predicciones out-of-fold.

La matriz OOF agregada contiene 401 TN, 38 FP, 86 FN y 187 TP, sumando las 712 observaciones de entrenamiento. Las métricas calculadas sobre OOF concatenado (accuracy = 0,8258, F1 = 0,7510) se reportan como evidencia complementaria. No se confunden con el promedio de métricas por fold, ya que métricas no lineales pueden diferir entre el promedio de folds y el cálculo sobre predicciones agregadas.

X. Justificación de técnica de validación

La técnica seleccionada es K-Fold Cross-Validation estratificada con $k=5$. La elección responde a tres dimensiones exigidas por la actividad: tamaño del conjunto de datos, costo computacional y estabilidad esperada. El conjunto de entrenamiento contiene 712 observaciones, tamaño moderado que permite reservar aproximadamente 142-143 casos para validación en cada iteración sin reducir excesivamente el entrenamiento.

Técnica	Ajustes	Costo	Ventaja/limitación	Decisión
Hold-Out	1	Bajo	Rápido y simple; sensible a una única partición.	Se conserva como evidencia histórica.
Stratified K-Fold $k=5$	5	Medio	Promedia varias particiones y conserva proporciones de clase.	Técnica principal de estabilidad.
LOOCV	712	Alto	Aprovecha $n-1$ casos por ajuste, pero requiere un ajuste por observación.	No se justifica para esta fase.

El tiempo total observado para los cinco ajustes externos fue 1.224 s en el entorno de la corrida. Este valor es descriptivo del equipo utilizado y no se generaliza como costo universal; la comparación de número de ajustes sí muestra el contraste estructural entre 5 entrenamientos externos y los 712 que requeriría LOOCV. El material docente identifica K-Fold como un equilibrio frecuente entre robustez y costo para datasets pequeños o moderados (Ruede Zúñiga, 2026b).

La estratificación no cambia la lógica de K-Fold: cada fold actúa una vez como validación y el resto como entrenamiento. Su ventaja en este caso es conservar aproximadamente la proporción 61,6/38,4 de las clases, evitando que diferencias marcadas de prevalencia dominen la comparación entre folds.

XI. Coherencia metodológica de validación

La coherencia metodológica se observa en la relación entre tipo de problema, datos, preprocesamiento, modelo, métricas y protocolo. El objetivo es binario; por ello se utilizan matriz de confusión y métricas de clase positiva. El MLP es sensible a la escala; por ello las variables numéricas se estandarizan. La imputación, codificación y escalamiento se encapsulan en el pipeline y se reajustan en cada fold, de modo que la validación no recibe información aprendida desde el fold retenido.

Dimensión	Decisión	Coherencia
Problema	Clasificación binaria	Matriz de confusión y métricas de clasificación.
Clase objetivo	Sobrevivió = 1	Precision, recall y F1 se interpretan sobre la clase positiva.
Preprocesamiento	Pipeline por fold	Evita aprendizaje de parámetros desde validación.
Modelo	MLP (100, 50)	Continuidad con la selección de Semana 3.
Validación	StratifiedKFold k=5	Conserva proporciones y estima variabilidad.
Test	Hold-Out histórico	No se utiliza para reoptimizar arquitectura, umbral o pipeline.
Resultados	Promedio + dispersión por fold	Distingue nivel de desempeño y estabilidad.

La comparación entre Hold-Out y CV se interpreta con cautela porque los protocolos utilizan muestras distintas. El promedio CV superior en accuracy y precision no implica que el modelo haya mejorado; refleja la variabilidad de la evaluación. La conclusión se centra en generalización y estabilidad, coherente con el principio de que el rendimiento observado depende del modelo, la métrica, el umbral y el protocolo de validación (Ruete Zúñiga, 2026a, 2026b).

XII. Notebook y trazabilidad del proceso de validación

El bloque de validación genera evidencia suficiente para reconstruir cada fold: tamaño de entrenamiento y validación, métricas, TN/FP/FN/TP, iteraciones del MLP, mejor validation score, loss final y tiempo de ajuste. ``18_predicciones_oof_cv.csv`` conserva una predicción out-of-fold para cada observación de train; ``16_matrices_confusion_cv_por_fold.csv`` y ``17_matriz_confusion_cv_agregada.csv`` permiten recalculer los errores; y ``19_balance_clases_cv.csv`` documenta la estratificación.

```
for cada fold:
    construir_pipeline()
    fit(X_train_fold, y_train_fold)
    predict / predict_proba sobre X_valid_fold
    calcular métricas + matriz
    almacenar predicción OOF
```

```
control final:
    cada índice train aparece una vez
    ningún índice test entra en OOF
    suma matriz OOF = 712
```

Evidencia	Archivo
Métricas por fold	14_metricas_cv_por_fold.csv
Estabilidad	15_resumen_estabilidad_cv.csv
Matrices por fold	16_matrices_confusion_cv_por_fold.csv
Matriz OOF agregada	17_matriz_confusion_cv_agregada.csv
Predicciones OOF	18_predicciones_oof_cv.csv
Balance de clases	19_balance_clases_cv.csv
Advertencias	20_advertencias_cv.csv
Costo	21_costo_validacion.csv
Manifiesto	39_manifiesto_artefactos.csv
Control de artefactos	40_control_artefactos_requeridos.csv

La última celda del notebook verifica consistencia numérica, continuidad con Semana 3, integridad de predicciones, ausencia de NaN después del preprocesamiento y existencia de los artefactos. En la corrida archivada, el control registra 50/50 artefactos requeridos presentes.

XIII. Conclusiones técnicas del proceso de validación

La validación cruzada estratificada cumple el objetivo de estimar el comportamiento del MLP más allá de una única partición. El accuracy medio de 0,8258 con SD muestral 0,0135 muestra baja variabilidad global, mientras el recall medio de 0,6850 con SD 0,0616 evidencia mayor sensibilidad de la detección de positivos a la composición de los folds.

K-Fold $k=5$ resulta coherente con el tamaño del conjunto de entrenamiento y con el costo del MLP. Frente a un único Hold-Out, aporta varias estimaciones; frente a LOOCV, evita 712 ajustes externos. La estratificación preserva la distribución de clases y el pipeline por fold evita filtración de información. En conjunto, estas decisiones satisfacen el propósito de ID4.2: justificar la técnica en términos de tamaño, costo y estabilidad.

Como proyección, una versión orientada a despliegue debería separar un conjunto final completamente independiente después de toda selección, o emplear nested cross-validation si se ajustan hiperparámetros dentro del proceso. Si el objetivo de negocio asigna distinto costo a FN y FP, el umbral debería optimizarse dentro de validación y nunca con el test final. Para probabilidades utilizadas directamente en decisiones, también sería pertinente evaluar calibración.

XIV. Uso de fuentes, citación y referencias

El informe integra material docente, documentación técnica oficial y bibliografía académica complementaria. Las fuentes docentes sustentan la interpretación de métricas, umbral y esquemas de validación; la documentación técnica respalda el uso de Pipeline, StratifiedKFold y MLPClassifier; y la bibliografía académica aporta el marco de generalización y evaluación de modelos. La implementación se mantiene coherente con el ecosistema scikit-learn descrito por Pedregosa et al. (2011).

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: With applications in Python*. Springer. <https://www.statlearning.com/>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., VanderPlas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830. <https://jmlr.org/papers/v12/pedregosa11a.html>

Ruete Zúñiga, D. (2026a). *Métricas de evaluación: accuracy, F1-score, curva ROC-AUC, curvas precisión-recall, matriz de confusión* [Apunte]. Universidad Andrés Bello.

Ruete Zúñiga, D. (2026b). *Técnicas de evaluación: validación cruzada (K-Fold Cross-Validation, Leave-One-Out Validation, Hold-Out Validation)* [Apunte]. Universidad Andrés Bello.

scikit-learn Developers. (s. f.-a). *Pipeline*. Scikit-learn documentation. <https://scikit-learn.org/1.4/modules/generated/sklearn.pipeline.Pipeline.html>

scikit-learn Developers. (s. f.-b). *StratifiedKFold*. Scikit-learn documentation. https://scikit-learn.org/1.4/modules/generated/sklearn.model_selection.StratifiedKFold.html

scikit-learn Developers. (s. f.-c). *MLPClassifier*. Scikit-learn documentation. https://scikit-learn.org/1.4/modules/generated/sklearn.neural_network.MLPClassifier.html

La distribución cumple y supera el mínimo exigido: dos fuentes docentes, tres fuentes técnicas oficiales y dos fuentes académicas complementarias. Todas las fuentes listadas son utilizadas en el desarrollo del informe.

XV. Anexos

Anexo A. Resultados completos del Hold-Out

Indicador	Valor
TN	92
FP	18
FN	19
TP	50
Accuracy	0,793296
Precision	0,735294
Recall	0,724638
F1	0,729927
Balanced accuracy	0,780501
Especificidad	0,836364
ROC-AUC	0,852174
Average precision	0,789082

Anexo B. Resultados por fold

Fold	N train	N val	Accuracy	Precision	Recall	F1
1	569	143	0,8322	0,8163	0,7273	0,7692
2	569	143	0,8182	0,8537	0,6364	0,7292
3	570	142	0,8451	0,8837	0,6909	0,7755
4	570	142	0,8239	0,7736	0,7593	0,7664
5	570	142	0,8099	0,8462	0,6111	0,7097

Anexo C. Trazabilidad de la rúbrica

Criterio	Evidencia	Artefactos
C1 Evaluación del desempeño	Notebook: secciones 2, 3, 4 y 6	04_diccionario_variables.csv; 22_metricas_holdout.csv; 23_matriz_confusion_holdout.csv
C2 Reporte tabulado de métricas	Notebook: sección 6	22_metricas_holdout.csv; 26_reporte_clasificacion_holdout.csv

Criterio	Evidencia	Artefactos
C3 Matriz de confusión y métricas	Notebook: sección 6	22_metricas_holdout.csv; 23_matriz_confusion_holdout.csv; figura 05
C4 Interpretación del desempeño	Evidencia cuantitativa para el informe	24_predicciones_holdout.csv; 25_errores_holdout.csv; 22_metricas_holdout.csv
C5 Toma de decisiones	Evidencia cuantitativa para el informe	30_control_umbral.csv; 35_comparacion_holdout_cv.csv; curvas ROC y PR
C6 Notebook y trazabilidad de evaluación	Flujo completo y control final	00-40 outputs; figuras 01-08; manifiesto
C7 Conclusiones del desempeño	Evidencia cuantitativa para el informe	22_metricas_holdout.csv; 25_errores_holdout.csv; 29_advertencias_holdout.csv
C8 Estabilidad de métricas	Notebook: sección 5	14_metricas_cv_por_fold.csv; 15_resumen_estabilidad_cv.csv; figuras 02-04
C9 Justificación de validación	Notebook: sección 4 y costo observado	13_protocolo_validacion.csv; 21_costo_validacion.csv
C10 Coherencia metodológica	Pipeline dentro de cada fold; CV solo en train	10b_verificacion_split_semana3.csv; 12_configuracion_evaluacion.csv; 19_balance_clases_cv.csv; 28_control_preprocesamiento.csv
C11 Notebook y trazabilidad de validación	Notebook: sección 5 y control final	14-21 outputs; 18_predicciones_oof_cv.csv; 39_manifiesto_artefactos.csv
C12 Conclusiones de validación	Evidencia cuantitativa para el informe	15_resumen_estabilidad_cv.csv; 21_costo_validacion.csv; 35_comparacion_holdout_cv.csv
C13 Portada e índice	No corresponde al cuaderno	Debe cubrirse en el informe final
C14 Formato institucional	No corresponde al cuaderno	Debe cubrirse en el PDF final
C15 Ortografía y gramática	Nomenclatura y documentación técnica formal	Revisión final del informe y notebook
C16 Fuentes y referencias	No sustituye la citación del informe	Debe cubrirse en el informe final con fuentes requeridas
C17 Anexos	Tablas y figuras reproducibles	Semana4/outputs/ y Semana4/figures/

Anexo D. Controles de reproducibilidad y entorno

Componente	Versión
Python	3.12.4
NumPy	1.26.4
pandas	2.2.2
scikit-learn	1.4.2
Matplotlib	3.8.4

Control	Resultado
Modelo	MLP (100, 50)
random_state	42
Hold-Out	80/20 estratificado
K-Fold	5 folds estratificados
Umbral	0,50
Optimización del umbral con test	No
Advertencias de convergencia	0
Control de artefactos	50/50

Archivos complementarios: `Semana4/outputs/`, `Semana4/figures/`, `Semana4/docs/` y `Semana4/notebook/F4\_Evaluacion.ipynb`.